



MIGS

**MASTER MATHÉMATIQUES
POUR L'INGÉNIERIE,
ALGORITHMIQUE ET STATISTIQUE
UNIVERSITÉ BOURGOGNE EUROPE**

UNIVERSITÉ DE BOURGOGNE

MASTER MIGS

Mathématiques pour l'Ingénierie, alGorithmique, Statistique

Analyse Statistique et Algorithmique du Modèle de Régression Logistique

Étudiants :

Nassim KHALISS
Yacine BETTANI

Superviseurs :

P. TARDIVEL
X. DUPUIS

Année Universitaire 2025-2026

Sommaire

Introduction	3
1 Le Modèle Logistique et le Principe de Vraisemblance	4
1.1 Le modèle statistique	4
1.1.1 Cadre général et Hypothèses fondamentales	4
1.1.2 Limites du Modèle Linéaire et Fonction de Lien	5
1.2 Formulation du problème d'optimisation	6
1.3 Justification théorique des hypothèses	7
1.3.1 Du Rang Plein à l'Unicité	7
1.3.2 Du Chevauchement à l'Existence	8
1.4 La Régularisation : Une Solution au Problème d'Existence	9
2 Méthodes Numériques d'Estimation	11
2.1 Méthode du Premier Ordre : La Descente de Gradient	11
2.1.1 Analyse de la Courbure et Constante de Lipschitz	11
2.1.2 Approche Adaptative : La Condition d'Armijo	12
2.1.3 Le problème du Conditionnement	12
2.1.4 Analyse de la Vitesse de Convergence	13
2.1.5 Extension aux Grands Jeux de Données (SGD)	13
2.2 Méthode du Second Ordre : L'Algorithme Newton-Raphson et l'IRLS	14
2.2.1 Le Principe de Newton-Raphson	14
2.2.2 Reformulation en Moindres Carrés Pondérés (IRLS)	14
2.2.3 Limites du Pas Pur et Newton Amorti (<i>Damped Newton</i>)	15
2.2.4 Pseudo-Code	16
2.2.5 Stabilité Numérique et Décomposition QR	16
2.2.6 Comparaison Algorithmique : Gradient et Newton-Raphson	17
2.3 Méthode de Second Ordre Approché : Quasi-Newton (BFGS)	17
2.3.1 Le Principe de la Condition Sécante	17
2.3.2 Approximation Directe de l'Inverse de la Hessienne	18
2.3.3 La Formule de Mise à Jour BFGS	18
2.3.4 Initialisation et Pseudo-Code	19
2.3.5 Analyse de Complexité et Convergence	20
3 Propriétés Asymptotiques et Inférence Statistique	21
3.1 Normalité Asymptotique de l'Estimateur	21
3.1.1 L'Information de Fisher : Mesure géométrique de l'incertitude	21
3.1.2 Convergence en Loi et Variance Asymptotique	22
3.2 Tests d'Hypothèses et Significativité	23

3.2.1	Le Test de Wald	23
3.2.2	Limites du Test de Wald : Le Paradoxe de Hauck-Donner	25
3.3	Interprétation des Coefficients : L'Odds Ratio	25
3.3.1	Des Probabilités aux Cotes (Odds)	25
3.3.2	Définition et Calcul de l'Odds Ratio	26
3.3.3	Intervalle de Confiance de l'Odds Ratio	26
3.4	Évaluation et Sélection de Modèles	27
3.4.1	La Déviance et le Test du Rapport de Vraisemblance	27
3.4.2	Critères d'Information : AIC et BIC	28
4	Applications sur Données Réelles et Évaluation des Algorithmes	29
4.1	Étude Statistique : Modélisation Biométrique de la Main	29
4.1.1	Présentation du Jeu de Données Biométriques	29
4.1.2	Démarche et Sélection des Modèles	30
4.1.3	Significativité Globale : Évaluation Comparative des Modèles	31
4.1.4	Validation de l'implémentation algorithmique	31
4.1.5	Inférence Statistique Locale : Que nous disent les variables ?	32
4.1.6	Performances de Classification : Les Outils d'Évaluation	33
4.1.7	Frontière de Décision et Généralisation	35
4.2	Stress-Test Algorithmique sur Données Massives	36
4.2.1	Présentation et Préparation du Jeu de Données	36
4.2.2	Analyse de la Convergence et Topologie du Coût	36
4.2.3	Comparaison des Estimateurs et Paradoxe de Hauck-Donner	38
4.2.4	Évaluation Prédicative et Stabilité du Modèle	40
4.2.5	Interprétabilité et Impact Socio-Économique des Variables	42
	Conclusion	44
A	Démonstrations Mathématiques	45
A.1	Inversion de la fonction Logit (Obtention de la Sigmoides)	45
A.2	Passage de la Vraisemblance à la log-vraisemblance	46
A.3	Calcul du Gradient (Détail par la règle de la chaîne)	46
A.4	Calcul de la matrice Hessienne (Par dérivation en chaîne)	48
A.5	Existence de l'Estimateur du Maximum de Vraisemblance lors du chevauchement	49
A.6	Majoration de la Hessienne et Constante de Lipschitz	51
A.7	Dérivation détaillée de Newton-Raphson	51
A.8	Équivalence Algébrique avec l'IRLS	53
A.9	Justification de la mise à jour BFGS	54
A.10	La distribution de Bernoulli et la famille exponentielle	55
A.11	Normalité Asymptotique de l'EMV	56
	Bibliographie	58

Introduction

La modélisation de phénomènes binaires constitue une routine de l'analyse statistique moderne. Dans de nombreux domaines, de l'épidémiologie à la finance, le praticien est confronté à la nécessité d'expliquer et de prédire une variable réponse ne pouvant prendre que deux états mutuellement exclusifs : un patient est sain ou malade, un client achète ou n'achète pas, une transaction est frauduleuse ou légitime.

Face à cette nature dichotomique, la variable cible suit intrinsèquement une loi de Bernoulli. L'objectif statistique fondamental n'est donc pas d'estimer une grandeur absolue, mais de modéliser l'espérance conditionnelle de cette loi, c'est-à-dire la probabilité de succès de l'évènement étudié. Cette exigence impose un cadre strict : la prédiction devant impérativement rester dans l'intervalle $[0, 1]$, il devient nécessaire d'appliquer une transformation non-linéaire (une fonction de lien) capable de projeter l'espace des combinaisons de variables explicatives ($\mathbb{R}$) vers cet espace probabiliste restreint. C'est précisément l'architecture rigoureuse que fournit la modélisation logistique.

Concrètement, en modélisant le logarithme du rapport des cotes (*logit*) plutôt que la probabilité brute, cette approche garantit des prédictions cohérentes tout en capturant la relation non linéaire entre les variables explicatives et la probabilité de succès. Cependant, ce gain de rigueur statistique s'accompagne d'une complexité calculatoire accrue. Contrairement au modèle linéaire, qui offre une solution analytique directe pour l'estimation de ses coefficients (via les équations normales), la régression logistique ne permet pas d'isoler les paramètres par une simple manipulation algébrique. L'estimation par maximum de vraisemblance conduit à un système d'équations non linéaires dont la résolution requiert impérativement le recours à l'analyse numérique.

L'objectif de ce mémoire est d'explorer en profondeur cette articulation entre théorie statistique et résolution algorithmique. Nous débiterons par une formalisation du modèle logistique et du principe du maximum de vraisemblance, en mettant en évidence l'impasse analytique qu'il soulève. Cette base théorique nous permettra, dans un second temps, d'étudier et de comparer les méthodes numériques d'optimisation. Nous opposerons l'approche classique de Newton-Raphson (IRLS), optimale en termes de convergence mais coûteuse en calcul matriciel, aux méthodes du premier ordre comme la descente de gradient, souvent privilégiées pour le traitement des données de grande dimension, tout en intégrant l'approche de Quasi-Newton via l'algorithme BFGS, qui offre un compromis performant en évitant le calcul direct de la matrice Hessienne. Enfin, après avoir établi les propriétés asymptotiques de l'Estimateur du Maximum de Vraisemblance, nous illustrerons ces concepts par une mise en œuvre pratique sur données réelles (jeu de données d'indice de Manning), validant ainsi la pertinence du modèle et l'efficacité des algorithmes implémentés.

L'élaboration de ce manuscrit a été facilitée par l'usage d'outils d'intelligence artificielle générative, sollicités exclusivement pour la révision linguistique (orthographe et syntaxe), l'appui à la recherche de références bibliographiques, ainsi que l'assistance technique liée à la mise en forme sous l'environnement LaTeX.

Chapitre 1

Le Modèle Logistique et le Principe de Vraisemblance

1.1 Le modèle statistique

1.1.1 Cadre général et Hypothèses fondamentales

Le cadre de notre étude se restreint à la modélisation d'une variable réponse binaire $Y \in \{0, 1\}$ (codant respectivement un échec et un succès, ou l'absence et la présence d'une caractéristique).

Considérons un échantillon de n couples de variables aléatoires $(Y_i, X_i)_{1 \leq i \leq n}$ identiquement distribués selon une loi jointe $P(Y, X)$. Pour chaque individu $i \in \{1, \dots, n\}$, on dispose des réalisations observées (y_i, x_i) , où :

- $y_i \in \{0, 1\}$ est la réalisation de la variable réponse $Y_i \sim \mathcal{B}(p_i)$.
- $x_i = (1, x_{i,1}, \dots, x_{i,p})^T \in \mathbb{R}^{p+1}$ est la réalisation du vecteur aléatoire de prédicteurs X_i .

Pour un individu i , la probabilité conditionnelle de succès est notée $p_i = \mathbb{P}(Y_i = 1 | X_i = x_i)$.

L'objectif central du modèle est d'estimer cette probabilité p_i en quantifiant l'influence de chaque variable explicative. Pour ce faire, nous introduisons un vecteur de paramètres inconnus $\beta = (\beta_0, \beta_1, \dots, \beta_p)^T \in \mathbb{R}^{p+1}$, où chaque coefficient β_j (pour $j \in \{1, \dots, p\}$) mesure l'effet spécifique de la j -ème variable sur la probabilité de succès, tandis que β_0 représente le coefficient constant (intercept).

Pour faciliter les développements algébriques, nous définissons le vecteur colonne des observations $y \in \mathbb{R}^n$ et la matrice de design $X \in \mathbb{R}^{n \times (p+1)}$ regroupant l'ensemble des réalisations :

$$y = \begin{pmatrix} y_1 \\ \vdots \\ y_i \\ \vdots \\ y_n \end{pmatrix} \leftarrow \text{Individu } i, \quad X = \begin{pmatrix} 1 & x_{1,1} & \dots & \overset{\text{Variable } j}{\downarrow} x_{1,j} & \dots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 1 & x_{i,1} & \dots & x_{i,j} & \dots & x_{i,p} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 1 & x_{n,1} & \dots & x_{n,j} & \dots & x_{n,p} \end{pmatrix} \leftarrow \text{Individu } i \text{ (Ligne } x_i^T \text{)}$$
(1.1)

Cette représentation matricielle permet d'isoler le scalaire $x_{i,j}$, qui représente la valeur spécifique de la j -ème variable observée pour le i -ème individu.

Avant de définir la forme fonctionnelle du modèle, nous formulons trois hypothèses structurelles sur les données :

1. **Indépendance de l'échantillon** : Les n couples de variables aléatoires (X_i, Y_i) sont supposés indépendants (c'est-à-dire que pour toute paire d'individus $i \neq j$, on a $\mathbb{P}((X_i, Y_i), (X_j, Y_j)) = \mathbb{P}(X_i, Y_i) \times \mathbb{P}(X_j, Y_j)$). Cette condition est indispensable pour pouvoir ultérieurement décomposer la vraisemblance jointe en un produit de vraisemblances marginales individuelles.
2. **Matrice de plein rang** : La matrice de design X , de dimension $n \times (p+1)$, est supposée de plein rang colonne ($\text{rang} = p+1$). Cela signifie qu'il n'existe pas de colinéarité parfaite entre les variables explicatives (aucune variable n'est une combinaison linéaire des autres). Cette hypothèse assurera l'identifiabilité des paramètres β et la stricte concavité de la fonction objectif.
3. **Chevauchement des classes (Overlap)** : Nous supposons que les classes d'observations $y_i = 0$ et $y_i = 1$ ne sont pas parfaitement séparables par un hyperplan dans l'espace des prédicteurs $\mathbb{R}^{p+1}$. Géométriquement, l'enveloppe convexe des points x_i dans $\mathbb{R}^{p+1}$ correspondant aux succès et celle correspondant aux échecs doivent avoir une intersection non vide. Comme nous le détaillerons en fin de chapitre, cette hypothèse, combinée à celle du rang plein, est requise pour garantir l'existence et l'unicité d'une solution finie pour les coefficients de l'Estimateur du Maximum de Vraisemblance.

1.1.2 Limites du Modèle Linéaire et Fonction de Lien

Historiquement, face à un problème de modélisation, le premier réflexe en statistique appliquée a longtemps consisté à s'appuyer sur l'outil le plus standard et le plus facile à estimer : la régression linéaire par la méthode des Moindres Carrés Ordinaires (MCO). Appliquée directement à une variable réponse binaire, cette tentative d'adaptation prend le nom de Modèle de Probabilité Linéaire (MPL). Comme le soulignent Hastie et al. [8, Chapitre 4] lors de l'étude de ses limites structurelles, cette approche naïve consiste à postuler pour chaque individu i l'équation classique suivante :

$$Y_i = x_i^T \beta + \epsilon_i$$

Sous l'hypothèse standard d'une erreur d'espérance nulle conditionnellement aux variables explicatives ($E(\epsilon_i|x_i) = 0$), l'espérance de la variable cible devient :

$$E(Y_i|x_i) = P(Y_i = 1|x_i) = x_i^T \beta$$

Ainsi, la probabilité de succès p_i est modélisée comme une simple combinaison linéaire des prédicteurs ($p_i = x_i^T \beta$). Cependant, l'application de ce modèle à une variable binaire soulève deux contradictions théoriques majeures qui invalident cette méthode :

- **Violation des bornes de probabilité** : Le terme linéaire $x_i^T \beta$ est à valeurs dans $\mathbb{R}$ tout entier ($] -\infty, +\infty[$). Or, la grandeur que nous modélisons est une probabilité, qui doit impérativement rester contrainte dans l'intervalle $[0, 1]$. Un modèle linéaire pourrait prédire des probabilités aberrantes (négatives ou supérieures à 1) pour des valeurs extrêmes de x_i .
- **Hétéroscédasticité des erreurs** : Le modèle de régression linéaire usuel exige que la variance des erreurs soit constante pour tous les individus (hypothèse d'homoscédasticité). Or, pour une réponse binaire, la variance dépend directement de l'espérance : $\text{Var}(Y_i) = p_i(1-p_i)$. Puisque cette probabilité p_i varie selon le profil x_i de chaque individu, la variance n'est structurellement pas constante. Cette condition fondamentale n'étant pas respectée, le théorème de Gauss-Markov ne s'applique plus : l'estimateur des moindres carrés ordinaires perd son optimalité et l'inférence statistique classique s'en trouve invalidée. L'approche linéaire est donc inadaptée.

Pour contourner ces obstacles, la régression logistique introduit une fonction de lien non linéaire. Plutôt que de modéliser directement la probabilité, nous modélisons le logarithme du rapport des cotes (*odds*), appelé **logit**. Le modèle postule que le logit est linéaire en les paramètres $\beta \in \mathbb{R}^{p+1}$:

$$\text{logit}(p_i(\beta)) = \ln \left(\frac{p_i(\beta)}{1 - p_i(\beta)} \right) = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} = x_i^T \beta. \quad (1.2)$$

La fonction logit étant une bijection de $]0, 1[$ sur $\mathbb{R}$, nous pouvons inverser cette relation (voir **Annexe A.1**) pour exprimer la probabilité en fonction des prédicteurs. Nous introduisons alors la fonction logistique (ou sigmoïde) $\pi : \mathbb{R} \rightarrow]0, 1[$, définie par $\pi(z) = \frac{1}{1 + \exp(-z)}$. En l'appliquant au prédicteur linéaire $x_i^T \beta$, la probabilité modélisée s'écrit :

$$p_i(\beta) = \pi(x_i^T \beta) = \frac{\exp(x_i^T \beta)}{1 + \exp(x_i^T \beta)} = \frac{1}{1 + \exp(-x_i^T \beta)}. \quad (1.3)$$

Remarquons que pour toute valeur finie de β , l'exponentielle est strictement positive, ce qui implique que $0 < p_i < 1$. La probabilité prédite ne peut jamais atteindre exactement 0 ou 1, sauf asymptotiquement.

1.2 Formulation du problème d'optimisation

L'estimation du vecteur de paramètres β constitue l'étape centrale de la modélisation. Comme nous l'avons souligné, la méthode des moindres carrés n'est pas adaptée à la nature binaire de la variable dépendante. Le cadre statistique approprié est celui du Maximum de Vraisemblance, qui consiste à rechercher les valeurs des paramètres rendant les données observées les plus probables possibles.

Considérons la loi de probabilité d'une observation unique y_i . Puisque Y_i suit une loi de Bernoulli, sa probabilité de succès p_i dépend intrinsèquement du vecteur de paramètres β via le prédicteur linéaire $\eta_i = x_i^T \beta$.

La fonction de masse pour l'individu i peut s'écrire sous une forme compacte unifiée :

$$P(Y_i = y_i | x_i) = p_i(\beta)^{y_i} (1 - p_i(\beta))^{1 - y_i}. \quad (1.4)$$

Si $y_i = 1$, l'expression vaut $p_i(\beta)$; si $y_i = 0$, elle vaut $1 - p_i(\beta)$.

En vertu de l'hypothèse d'indépendance des observations (Hypothèse 1 posée en section 1.1), la probabilité jointe d'observer l'échantillon complet $y = (y_1, \dots, y_n)^T$ est égale au produit des probabilités marginales. Nous définissons ainsi la fonction de Vraisemblance $L(\beta)$:

$$L(\beta) = \prod_{i=1}^n p_i(\beta)^{y_i} (1 - p_i(\beta))^{1 - y_i}. \quad (1.5)$$

La manipulation analytique d'un produit de probabilités pose deux problèmes : le calcul des dérivées devient lourd, et la multiplication de nombreuses probabilités crée des valeurs trop faibles pour être gérées précisément par un ordinateur (risque d'*underflow*). Pour pallier ces difficultés, nous définissons formellement la **log-vraisemblance**, notée $\ell(\beta)$, comme le logarithme népérien de la fonction de vraisemblance $L(\beta)$. La fonction logarithme étant strictement croissante sur $]0, +\infty[$, maximiser $L(\beta)$ est équivalent à maximiser $\ell(\beta)$. Cette transformation convertit le produit en somme, rendant l'expression beaucoup plus maniable (**Annexe A.2**) :

$$\ell(\beta) = \ln(L(\beta)) = \sum_{i=1}^n [y_i \ln(p_i(\beta)) + (1 - y_i) \ln(1 - p_i(\beta))] . \quad (1.6)$$

De plus, comme nous le démontrerons formellement à la Section 1.3.1, cette fonction possède la propriété cruciale d'être strictement concave grâce à nos hypothèses, garantissant ainsi l'unicité de la solution.

En explicitant la fonction $p_i(\beta)$ selon sa première expression définie à l'Équation (1.3), les logarithmes se simplifient pour donner la forme explicite indispensable à l'optimisation numérique :

$$\ell(\beta) = \sum_{i=1}^n [y_i(x_i^T \beta) - \ln(1 + \exp(x_i^T \beta))] . \quad (1.7)$$

Nous définissons formellement l'**Estimateur du Maximum de Vraisemblance**, noté $\hat{\beta}$, comme le vecteur de paramètres qui maximise la fonction de log-vraisemblance, tel que $\hat{\beta} = \arg \max_{\beta \in \mathbb{R}^{p+1}} \ell(\beta)$. Pour

trouver ce point optimal, nous cherchons le point critique où le gradient de la fonction s'annule. Ce vecteur des dérivées partielles premières, communément appelé **vecteur score**, s'obtient en dérivant $\ell(\beta)$ par rapport à chaque composante β_j . Après application de la règle de dérivation en chaîne (voir démonstration détaillée en **Annexe A.3**), nous obtenons le système d'équations suivant :

$$\nabla \ell(\beta) = \sum_{i=1}^n x_i(y_i - p_i(\beta)) = X^T(y - p(\beta)) = 0 \quad (1.8)$$

où y est le vecteur colonne des réalisations observées et $p(\beta) = (p_1(\beta), \dots, p_n(\beta))^T$ le vecteur des probabilités paramétrées par le modèle.

Nous touchons ici au cœur de la difficulté mathématique qui justifie ce mémoire. L'équation (1.8) est non linéaire en β . En effet, le vecteur $p(\beta)$ contient les termes sigmoïdes $\frac{1}{1 + \exp(-x_i^T \beta)}$. Contrairement au modèle linéaire gaussien où la solution s'exprime explicitement par la formule $\hat{\beta} = (X^T X)^{-1} X^T y$, il est ici algébriquement impossible d'isoler β pour obtenir une forme close. La résolution de ce système nécessite le recours à des algorithmes numériques itératifs.

1.3 Justification théorique des hypothèses

Le problème central de notre modélisation se formule comme un problème d'optimisation sans contrainte, consistant à maximiser la fonction de log-vraisemblance sur l'espace des paramètres :

$$(\mathcal{P}) \quad : \quad \max_{\beta \in \mathbb{R}^{p+1}} \ell(\beta) . \quad (1.9)$$

La pose formelle de ce problème $(\mathcal{P})$ nous permet désormais de justifier rigoureusement les hypothèses structurelles posées dans la section 1.1. L'analyse des propriétés de la fonction objectif $\ell(\beta)$, et plus particulièrement de sa matrice Hessienne, va nous éclairer sur les conditions requises pour garantir l'existence et l'unicité de la solution $\hat{\beta}$.

1.3.1 Du Rang Plein à l'Unicité

L'unicité de la solution au problème d'optimisation $(\mathcal{P})$ est directement liée à la stricte concavité de la fonction log-vraisemblance. Cette propriété géométrique repose fondamentalement sur l'hypothèse de plein rang de la matrice des prédicteurs X .

Pour en comprendre la nécessité, supposons dans un premier temps que cette hypothèse ne soit pas vérifiée, c'est-à-dire que $\dim(\ker(X)) \geq 1$. Il existerait alors un vecteur non nul $v \in \mathbb{R}^{p+1}$ tel que $Xv = 0$. Pour tout vecteur de paramètres β , considérons la translation $\beta' = \beta + v$. Le prédicteur linéaire pour chaque individu i resterait inchangé :

$$x_i^T \beta' = x_i^T (\beta + v) = x_i^T \beta + x_i^T v = x_i^T \beta \quad (\text{car } Xv = 0 \implies x_i^T v = 0). \quad (1.10)$$

Comme la log-vraisemblance $\ell(\beta)$ ne dépend de β qu'à travers ces produits scalaires, on en déduirait que $\ell(\beta') = \ell(\beta)$. Ainsi, si $\hat{\beta}$ était une solution, tout point de la droite $\{\hat{\beta} + \lambda v, \lambda \in \mathbb{R}\}$ le serait également. La fonction serait concave, mais non strictement concave, rendant le modèle non identifiable.

Afin d'établir formellement la stricte concavité sous l'hypothèse de plein rang, nous devons examiner la dérivée seconde de la log-vraisemblance, c'est-à-dire la matrice Hessienne $H(\beta)$. Le calcul direct est détaillé en **Annexe A.4** :

$$H(\beta) = \nabla^2 \ell(\beta) = -X^T W(\beta) X \quad (1.11)$$

où $W(\beta)$ est une matrice diagonale contenant les termes $w_{i,i} = p_i(\beta)(1 - p_i(\beta))$.

Puisque les probabilités paramétrées $p_i(\beta)$ sont strictement comprises dans l'intervalle ouvert $]0, 1[$, les poids $w_{i,i}$ sont strictement positifs. La matrice $W(\beta)$ est donc définie positive. C'est ici que l'hypothèse de **rang plein** de la matrice X (Hypothèse 2) joue son rôle crucial. Si X est de plein rang, alors la matrice $X^T W(\beta) X$ est définie positive.

Par conséquent, la matrice Hessienne $H(\beta)$ est définie négative sur tout l'espace des paramètres $\mathbb{R}^{p+1}$. Cela implique que la fonction de log-vraisemblance est **strictement concave**. En optimisation convexe, cette propriété est fondamentale : elle garantit que le problème ne possède pas de maximum locaux multiples. Si un maximum existe, il est nécessairement global et unique.

1.3.2 Du Chevauchement à l'Existence

Même si la matrice de design X est de plein rang, l'existence de l'estimateur du Maximum de Vraisemblance (c'est-à-dire l'existence d'un $\hat{\beta}$ fini) n'est pas garantie dans le modèle logistique. Ce phénomène est purement géométrique et dépend de la disposition des points dans l'espace des variables explicatives.

En s'appuyant sur l'analyse convexe, Albert et Anderson (1984) [4] ont rigoureusement classifié la topologie des données en deux configurations distinctes :

1. **La séparation (complète ou quasi-complète)** : Ce cas survient lorsqu'il existe un hyperplan capable de séparer les deux classes. On distingue la *séparation complète*, où les enveloppes convexes des observations ($y = 0$ et $y = 1$) sont strictement disjointes, de la *séparation quasi-complète*, où ces enveloppes s'intersectent uniquement sur leur frontière. Dans cette dernière situation, bien que l'intersection soit topologiquement non vide (au moins une observation de chaque groupe se situe sur l'hyperplan), l'intérieur de l'intersection reste vide. Dans les deux configurations, pour s'approcher du supremum de la log-vraisemblance (modélisant ainsi une fonction de saut parfaite), la norme du vecteur de paramètres doit nécessairement diverger ($\|\beta\| \rightarrow \infty$). L'espace admissible des paramètres étant $\mathbb{R}^{p+1}$, cette limite n'y appartient pas ; l'Estimateur du Maximum de Vraisemblance n'existe donc pas.
2. **Le chevauchement strict (*Overlap*)** : Il s'agit de la seule configuration où l'estimateur existe et est unique. Pour l'atteindre, il ne suffit pas que les enveloppes convexes se touchent ; il faut formellement que **les intérieurs relatifs de ces enveloppes convexes aient une intersection non vide**. Dès lors, aucun hyperplan ne peut séparer les classes, ni strictement, ni au sens large (la preuve est en Annexe A.5).

C'est cette condition de chevauchement strict (également formalisée par Silvapulle en 1981 [3] via l'intersection de cônes convexes) qui assure que la fonction de log-vraisemblance ne possède aucune direction de récession. Si les données se chevauchent, la vraisemblance tend asymptotiquement vers $-\infty$ dans toutes les directions, garantissant ainsi que la fonction, étant strictement concave, admet un maximum global unique dans $\mathbb{R}^{p+1}$.




FIGURE 1.1 – Représentation des conditions d'existence de l'Estimateur du Maximum de Vraisemblance dans un espace à deux variables explicatives. Les points représentent les observations réelles ($y = 1$ et $y = 0$) et les zones ombrées illustrent leurs enveloppes convexes respectives. **À gauche :** Séparation complète ($\|\hat{\beta}\| \rightarrow \infty$). **Au centre :** Séparation quasi-complète (intersection uniquement sur l'hyperplan séparateur). **À droite :** Chevauchement strict (intersection des intérieurs relatifs), seule configuration garantissant l'existence d'un vecteur $\hat{\beta}$ fini.

1.4 La Régularisation : Une Solution au Problème d'Existence

Nous avons établi dans la section précédente, via les travaux d'Albert et Anderson [4], qu'en l'absence de chevauchement strict des données (séparation complète ou quasi-complète), l'Estimateur du Maximum de Vraisemblance n'admet pas de solution finie (la norme des coefficients diverge vers l'infini, $\|\hat{\beta}\| \rightarrow \infty$).

Face à ce phénomène, exclure les variables explicatives responsables de la séparation reviendrait à écarter l'information statistique la plus prédictive. L'approche standard en apprentissage statistique consiste plutôt à contraindre l'espace des paramètres. C'est le principe de la régularisation par pénalisation L_2 , couramment appelée régression **Ridge**, dont l'application formelle à la régression logistique a été établie par le Cessie et van Houwelingen [13].

L'idée est d'ajouter un terme de pénalité directement à la fonction de log-vraisemblance. La fonction objectif pénalisée s'écrit :

$$\ell_{\text{Ridge}}(\beta) = \ell(\beta) - \frac{\lambda}{2} \|\beta\|_2^2 \quad (1.12)$$

où $\lambda > 0$ est un hyperparamètre de régularisation. Ce paramètre n'est pas estimé par le modèle d'optimisation interne mais fixé *a priori*, et sa valeur est généralement sélectionnée par validation croisée (*cross-validation*) afin de minimiser l'erreur de prédiction sur de nouvelles données.

L'ajout de cette pénalité modifie la topologie de la fonction cible. Rappelons que la fonction de

log-vraisemblance standard s'écrit :

$$\ell(\beta) = \sum_{i=1}^n [y_i \ln(p_i(\beta)) + (1 - y_i) \ln(1 - p_i(\beta))] . \quad (1.13)$$

Puisque la variable réponse y_i prend exclusivement les valeurs 0 ou 1, chaque contribution individuelle dans la somme se réduit soit à $\ln(p_i(\beta))$, soit à $\ln(1 - p_i(\beta))$. Les probabilités prédites appartenant à l'intervalle $]0, 1[$, leurs logarithmes sont systématiquement négatifs. Par conséquent, la log-vraisemblance $\ell(\beta)$ est majorée par 0. Le terme de pénalité $-\frac{\lambda}{2} \|\beta\|_2^2$, quant à lui, tend vers $-\infty$ lorsque la norme $\|\beta\|$ croît indéfiniment. La somme des deux termes tend donc vers $-\infty$. La fonction $\ell_{\text{Ridge}}(\beta)$ étant continue, strictement concave et tendant vers $-\infty$ aux limites de son domaine (ce qui équivaut à dire que son opposé est une fonction **coercive** sur un espace de dimension finie), les théorèmes fondamentaux de l'optimisation garantissent l'existence et l'unicité d'un maximum global fini.

Cette modification topologique se traduit algébriquement sur les dérivées de la log-vraisemblance. Le gradient et la matrice Hessienne pénalisés deviennent respectivement :

$$\nabla \ell_{\text{Ridge}}(\beta) = \nabla \ell(\beta) - \lambda \beta , \quad (1.14)$$

$$\nabla^2 \ell_{\text{Ridge}}(\beta) = -X^T W(\beta) X - \lambda I_p . \quad (1.15)$$

L'équation de la Hessienne démontre algébriquement la résolution du problème de singularité. Par construction, la matrice $-X^T W(\beta) X$ est semi-définie négative. La matrice diagonale $-\lambda I_p$ possède des valeurs propres toutes égales à $-\lambda < 0$, elle est donc définie négative. En algèbre linéaire, la somme d'une matrice semi-définie négative et d'une matrice définie négative donne systématiquement une matrice définie négative. Ainsi, la Hessienne pénalisée est garantie d'être inversible en tout point, y compris lorsque le terme de variance $W(\beta)$ s'annule aux bords de l'espace.

Bien que cette inversibilité soit une condition nécessaire pour autoriser l'exécution des algorithmes du second ordre (comme Newton-Raphson), elle n'est pas suffisante pour assurer à elle seule la convergence algorithmique. Elle agit comme un conditionnement de l'espace de recherche qui doit obligatoirement être couplé à une recherche linéaire (telle que la condition d'Armijo abordée au Chapitre 2) pour maîtriser la taille des pas d'optimisation.

Enfin, cette approche illustre le compromis biais-variance fondamental en statistique : on accepte d'introduire un biais dans l'estimation (les coefficients sont artificiellement contraints vers zéro) au profit d'une réduction drastique de la variance, assurant ainsi l'existence et la robustesse du modèle face aux configurations de données pathologiques.

Chapitre 2

Méthodes Numériques d'Estimation

Comme nous l'avons établi au chapitre précédent, l'annulation du gradient de la log-vraisemblance ne permet pas d'obtenir une solution analytique fermée pour $\hat{\beta}$. Par conséquent, bien que le problème soit déjà posé sous la forme d'une optimisation sans contraintes, sa résolution nécessite le recours à des méthodes d'optimisation numérique. Ce chapitre détaille les trois grandes familles d'algorithmes itératifs permettant d'approcher la solution : les méthodes de premier ordre (Descente de Gradient), les méthodes du second ordre (Newton-Raphson) et les méthodes de Quasi-Newton (BFGS).

2.1 Méthode du Premier Ordre : La Descente de Gradient

Pour les besoins de l'optimisation numérique abordée dans la suite de ce chapitre, le problème de maximisation de la log-vraisemblance est formulé de manière équivalente comme la minimisation de la fonction objective $J(\beta)$, définie comme l'opposé de la log-vraisemblance :

$$J(\beta) = -\ell(\beta) = -\sum_{i=1}^n [y_i \ln(p_i(\beta)) + (1 - y_i) \ln(1 - p_i(\beta))] .$$

La méthode d'optimisation la plus élémentaire pour minimiser cette fonction est l'algorithme de **Descente de Gradient** (*Gradient Descent*). Il s'agit d'une méthode du premier ordre qui n'exploite que l'information du gradient $\nabla J(\beta) = -\nabla \ell(\beta)$. L'algorithme procède de manière itérative en mettant à jour les paramètres dans la direction opposée au gradient, c'est-à-dire la direction de plus profonde descente :

$$\beta^{(k+1)} = \beta^{(k)} - \alpha_k \nabla J(\beta^{(k)}) \quad (2.1)$$

où $\alpha_k > 0$ désigne le pas d'apprentissage (*learning rate*). Le choix méticuleux de ce scalaire est crucial pour assurer la convergence de l'algorithme vers le minimum global.

2.1.1 Analyse de la Courbure et Constante de Lipschitz

Pour établir des garanties théoriques de convergence, notamment dans le cas d'un pas fixe, il est nécessaire d'étudier la régularité de la fonction objectif. Une condition suffisante classique est que le gradient de la fonction de coût soit Lipschitzien, ce qui revient à dire que la courbure de la fonction est majorée.

Dans le cas de la régression logistique, nous montrons en **Annexe A.6** que la courbure est majorée. Cette propriété découle directement du fait que les poids $w_i = p_i(1 - p_i)$ de la matrice W (définie en section 1.3.1) ne dépassent jamais $1/4$, valeur maximale de la variance d'une loi de Bernoulli.

Nous établissons ainsi que la Hessienne de la fonction de coût $J(\beta)$ est majorée, au sens de Loewner, par une matrice constante dépendant uniquement de la matrice des données :

$$\nabla^2 J(\beta) = X^T W X \preceq \frac{1}{4} X^T X. \quad (2.2)$$

Cette majoration permet de définir la constante de Lipschitz L du gradient, correspondant à la plus grande valeur propre de cette borne (voir démonstration en Annexe A.6) :

$$L = \frac{1}{4} \lambda_{\max}(X^T X) = \frac{1}{4} \|X\|_2^2. \quad (2.3)$$

La théorie de l'optimisation convexe garantit, d'après Bertsekas [6, Proposition 1.2.3], que la descente de gradient avec un pas fixe α converge vers le minimum global si :

$$0 < \alpha < \frac{2}{L}. \quad (2.4)$$

Le taux de convergence optimal théorique est atteint pour $\alpha = 1/L$. Bien que cette approche garantisse la stabilité de l'algorithme, elle peut s'avérer conservatrice (sous-optimale) en pratique, car le pas est calibré sur la courbure maximale rencontrée sur l'ensemble de l'espace des paramètres.

2.1.2 Approche Adaptative : La Condition d'Armijo

Pour pallier la lenteur du pas fixe et éviter le calcul coûteux de la plus grande valeur propre de $X^T X$, les implémentations robustes privilégient une recherche linéaire pour adapter α_k à chaque itération.

La règle standard, recommandée par Nocedal et Wright [7, Section 3.1], est la **condition d'Armijo**. Elle stipule que le pas choisi doit assurer une décroissance suffisante de la fonction de coût, proportionnelle à la pente locale. On cherche α satisfaisant l'inégalité :

$$J(\beta^{(k)} - \alpha \nabla J(\beta^{(k)})) \leq J(\beta^{(k)}) - c_1 \alpha \|\nabla J(\beta^{(k)})\|^2 \quad (2.5)$$

où $\nabla J(\beta^{(k)})$ est le gradient à l'étape courante et $c_1 \in (0, 1)$ est une constante de relaxation (typiquement 10^{-4}).

En pratique, on utilise un algorithme de rebroussement :

1. On initialise un pas relativement grand (ex : $\alpha = 1$).
2. Tant que la condition d'Armijo (2.5) n'est pas vérifiée, on réduit le pas géométriquement : $\alpha \leftarrow \tau \alpha$ (avec $\tau \approx 0.5$).
3. Une fois la condition satisfaite, on valide le pas et on effectue la mise à jour : $\beta^{(k+1)} = \beta^{(k)} - \alpha \nabla J(\beta^{(k)})$.

Cette méthode combine sécurité (convergence garantie d'après Bertsekas [6, Proposition 1.2.1]) et efficacité (adaptation à la topologie locale).

2.1.3 Le problème du Conditionnement

La descente de gradient standard avance de manière orthogonale aux courbes de niveau de la fonction de coût $J(\beta)$. Lorsque les variables explicatives ont des échelles très disparates (par exemple, des proportions entre 0 et 1 face à des mesures de plusieurs centaines d'unités), la fonction de coût prend la forme d'une vallée étroite et allongée. Le problème d'optimisation est alors dit **mal conditionné**.

Face à cette topologie, la direction du gradient $\nabla J(\beta)$ ne pointe pas directement vers le minimum global. L'algorithme subit un phénomène d'oscillation sévère (effet de *zig-zag*), rebondissant d'une paroi à l'autre de la vallée sans avancer efficacement. L'algorithme progresse de manière excessivement lente, voire échoue à converger dans un temps de calcul raisonnable.

Pour pallier ce défaut géométrique, la théorie de l'optimisation propose deux grandes alternatives :

1. **Agir sur les données (Standardisation)** : Il s'agit de centrer et de réduire les colonnes de la matrice X . Cette transformation ramène les variables à une échelle commune, ce qui « sphérise » les courbes de niveau et permet au gradient $\nabla J(\beta)$ d'être efficace.
2. **Agir sur l'algorithme (Changement de métrique)** : Au lieu de modifier les données, on modifie la direction de descente. En multipliant le gradient par une matrice de transformation définie positive (typiquement l'inverse de la matrice Hessienne $H(\beta)^{-1}$ ou une de ses approximations), on corrige dynamiquement l'étirement de l'espace. C'est très exactement l'essence des méthodes du second ordre (Newton-Raphson) et de Quasi-Newton (BFGS), justifiant ainsi le recours aux algorithmes de la section suivante dès lors que les données ne sont pas standardisées.

2.1.4 Analyse de la Vitesse de Convergence

La descente de gradient présente une convergence dite **linéaire**. Au voisinage de l'optimum β^* , d'après Bertsekas [6, Section 1.3], la réduction de l'erreur à chaque itération est bornée par l'inégalité suivante :

$$\|\beta^{(k+1)} - \beta^*\| \leq \left(\frac{\kappa - 1}{\kappa + 1} \right) \|\beta^{(k)} - \beta^*\| \quad (2.6)$$

où κ représente le **nombre de conditionnement** de la Hessienne évaluée à l'optimum β^* :

$$\kappa = \frac{\lambda_{\max}(\nabla^2 J(\beta^*))}{\lambda_{\min}(\nabla^2 J(\beta^*))} \geq 1. \quad (2.7)$$

Cette inégalité met en évidence la limite structurelle du gradient :

- Si les variables explicatives sont peu corrélées ($\kappa \approx 1$), le terme de réduction est proche de 0 et la convergence est rapide.
- Si le problème est mal conditionné ($\kappa \gg 1$, « vallée étroite »), le ratio $\frac{\kappa-1}{\kappa+1}$ s'approche de 1. L'algorithme progresse alors très lentement en effectuant de nombreux zigzags inutiles (phénomène d'oscillation).

2.1.5 Extension aux Grands Jeux de Données (SGD)

L'algorithme présenté jusqu'ici est qualifié de descente de gradient « Batch » (ou par lot), car chaque mise à jour nécessite le calcul du gradient exact, impliquant la sommation des contributions de l'ensemble des n observations :

$$\beta^{(k+1)} = \beta^{(k)} - \alpha^{(k)} \left(\sum_{i=1}^n x_i (p_i(\beta^{(k)}) - y_i) \right). \quad (2.8)$$

Comme le soulignent Hastie, Tibshirani et Friedman [8], cette évaluation globale devient redondante et inefficace lorsque n atteint plusieurs millions d'individus.

Pour répondre aux défis posés par les volumes de données massifs, on privilégie la **Descente de Gradient Stochastique** (SGD) ou sa variante par mini-lots (*Mini-batch*). Au lieu d'utiliser la

totalité de la matrice X , on estime le gradient de la fonction de coût $J(\beta)$ sur un sous-ensemble aléatoire $\mathcal{B}^{(k)}$ des données :

$$\beta^{(k+1)} = \beta^{(k)} - \alpha^{(k)} \left(\sum_{i \in \mathcal{B}^{(k)}} x_i (p_i(\beta^{(k)}) - y_i) \right). \quad (2.9)$$

Bien que cette estimation du gradient soit bruitée, elle permet d'effectuer un grand nombre de mises à jour de paramètres pour un coût de calcul équivalent à une seule itération de la méthode « Batch », permettant souvent d'atteindre une solution acceptable de manière beaucoup plus rapide.

2.2 Méthode du Second Ordre : L'Algorithme Newton-Raphson et l'IRLS

C'est la sensibilité au conditionnement des données (illustrée par le paramètre κ) qui justifie l'usage de méthodes du second ordre. En exploitant la courbure exacte de la fonction objectif, la méthode de référence, privilégiée par un grand nombre de logiciels statistiques standards (R, SAS, Python statsmodels), est l'algorithme de Newton-Raphson.

Cette méthode se distingue par sa vitesse de convergence quadratique : une fois proche de la solution, le nombre de décimales exactes double à chaque itération. Nous verrons que dans le cadre spécifique des GLM (Generalized Linear Models), cet algorithme prend la forme élégante d'une succession de régressions linéaires pondérées, connue sous le nom d'IRLS (*Iteratively Reweighted Least Squares*).

2.2.1 Le Principe de Newton-Raphson

Dans la section précédente, l'optimisation a été formulée comme la minimisation d'une fonction de coût $J(\beta)$. Dès lors, l'objectif est de trouver le vecteur de paramètres $\hat{\beta}$ qui annule le gradient de la fonction de coût, c'est-à-dire résoudre l'équation non-linéaire $\nabla J(\beta) = 0$.

Le principe fondamental de la méthode de Newton est d'approximer localement cette fonction de coût par une fonction quadratique (une parabole en dimension 1, un parabolöide en dimension p). En utilisant un développement de Taylor au second ordre autour de l'estimation courante $\beta^{(k)}$, on écrit :

$$J(\beta) \approx J(\beta^{(k)}) + (\beta - \beta^{(k)})^T \nabla J(\beta^{(k)}) + \frac{1}{2} (\beta - \beta^{(k)})^T \nabla^2 J(\beta^{(k)}) (\beta - \beta^{(k)}). \quad (2.10)$$

Pour trouver le prochain candidat $\beta^{(k+1)}$, on minimise cette approximation quadratique en annulant sa dérivée (**Annexe A.7**). Cela conduit à la relation de récurrence standard de Newton :

$$\beta^{(k+1)} = \beta^{(k)} - [\nabla^2 J(\beta^{(k)})]^{-1} \nabla J(\beta^{(k)}) \quad (2.11)$$

où $\nabla^2 J(\beta^{(k)})$ est la matrice Hessienne de la fonction de coût évaluée à l'étape k . Comme établi au Chapitre 1, la matrice $X^T W(\beta) X$ est définie positive, ce qui garantit que $\nabla^2 J(\beta^{(k)})$ l'est également et que nous nous déplaçons bien vers un minimum.

2.2.2 Reformulation en Moindres Carrés Pondérés (IRLS)

C'est ici que l'analyse devient particulièrement intéressante pour le statisticien. En remplaçant le gradient et la Hessienne par leurs expressions matricielles explicites ($\nabla J(\beta) = X^T (\mathbf{p}(\beta) - \mathbf{y})$ et $\nabla^2 J(\beta) = X^T W(\beta) X$), évaluées à l'itération courante $\beta^{(k)}$, l'équation de mise à jour de Newton (2.11) s'écrit d'abord de manière explicite :

$$\beta^{(k+1)} = \beta^{(k)} + (X^T W(\beta^{(k)}) X)^{-1} X^T (\mathbf{y} - \mathbf{p}(\beta^{(k)})). \quad (2.12)$$

Afin d'alléger l'écriture pour les développements matriciels qui suivent, on adopte la notation compacte $W^{(k)} \equiv W(\beta^{(k)})$ et $\mathbf{p}^{(k)} \equiv \mathbf{p}(\beta^{(k)})$. L'équation se simplifie alors sous la forme :

$$\beta^{(k+1)} = \beta^{(k)} + (X^T W^{(k)} X)^{-1} X^T (\mathbf{y} - \mathbf{p}^{(k)}) . \quad (2.13)$$

À première vue, cette formule semble complexe. Cependant, Hastie, Tibshirani et Friedman [8, Section 4.4.1] montrent qu'elle peut être réinterprétée intuitivement. L'idée est de « linéariser » le problème autour de la prédiction actuelle.

En utilisant l'identité matricielle $I = W^{(k)}(W^{(k)})^{-1}$ et en factorisant par la matrice d'information $(X^T W^{(k)} X)^{-1} X^T W^{(k)}$ (voir Démonstration A.7), on obtient l'expression factorisée suivante :

$$\beta^{(k+1)} = (X^T W^{(k)} X)^{-1} X^T W^{(k)} \left[X \beta^{(k)} + (W^{(k)})^{-1} (\mathbf{y} - \mathbf{p}^{(k)}) \right] . \quad (2.14)$$

Le terme entre crochets joue un rôle crucial. Il représente une version linéarisée de la variable réponse, ajustée par l'erreur courante normalisée par la variance locale. Comme le souligne Rakotomalala [1, Section 1.4], on définit ainsi la **variable de travail** ou **réponse ajustée** $\mathbf{z}^{(k)}$:

$$\mathbf{z}^{(k)} = \boldsymbol{\eta}^{(k)} + (W^{(k)})^{-1} (\mathbf{y} - \mathbf{p}^{(k)}) \quad (2.15)$$

où $\boldsymbol{\eta}^{(k)} = X \beta^{(k)}$ est le prédicteur linéaire.

En substituant $\mathbf{z}^{(k)}$ dans l'équation (2.14), la règle de mise à jour s'écrit sous une forme matricielle très compacte :

$$\beta^{(k+1)} = (X^T W^{(k)} X)^{-1} X^T W^{(k)} \mathbf{z}^{(k)} . \quad (2.16)$$

On reconnaît immédiatement dans cette expression la solution analytique classique (« Équations Normales ») d'une régression linéaire pondérée. En effet, ce vecteur est l'unique solution minimisant la somme des carrés pondérés des écarts :

$$\beta^{(k+1)} = \arg \min_{\beta} \sum_{i=1}^n w_{i,i}^{(k)} (z_i^{(k)} - \mathbf{x}_i^T \beta)^2 . \quad (2.17)$$

Cette identification formelle a une conséquence majeure : minimiser la fonction de coût logistique revient à résoudre itérativement un problème de Moindres Carrés, où la variable cible $\mathbf{z}^{(k)}$ et la matrice de poids $W^{(k)}$ changent à chaque itération. C'est l'origine de l'appellation **IRLS** (*Iteratively Reweighted Least Squares*).

2.2.3 Limites du Pas Pur et Newton Amorti (*Damped Newton*)

Bien que la méthode de Newton-Raphson bénéficie d'une convergence locale quadratique (le nombre de décimales exactes doublant à chaque itération près de l'optimum), son application sous sa forme « pure » présente une vulnérabilité algorithmique majeure.

L'équation de mise à jour repose sur un développement de Taylor au second ordre qui n'est qu'une approximation *locale* de la fonction de coût. Si le point de départ $\beta^{(0)}$ est trop éloigné de la solution réelle, la direction calculée $\Delta\beta = -[\nabla^2 J(\beta)]^{-1} \nabla J(\beta)$ peut induire un pas d'une amplitude excessive. Dans le cadre de la régression logistique, ce phénomène d'*overshooting* (dépassement) projette les coefficients dans des régions de l'espace où les probabilités $p_i(\beta)$ saturent vers 0 ou 1, un problème de divergence formellement identifié par McCullagh et Nelder [2, Section 4.4.2]. La variance locale $w_{i,i}(\beta) = p_i(\beta)(1 - p_i(\beta))$ s'effondre alors vers zéro, ce qui rend la matrice Hessienne quasi-singulière pour les itérations suivantes et provoque l'échec de l'algorithme.

Pour garantir une convergence globale (c'est-à-dire depuis n'importe quel point initial), l'optimisation numérique moderne n'utilise jamais l'algorithme de Newton pur, mais une variante appelée **Newton Amorti** (*Damped Newton*), rigoureusement démontrée par Nocedal et Wright [7, Section 3.1].

Le principe consiste à coupler la direction de Newton avec une recherche linéaire (par exemple, la condition de décroissance d'Armijo présentée à la Section 2.1.2). On introduit un scalaire $\alpha_k \in (0, 1]$ pour contrôler la longueur du pas :

$$\beta^{(k+1)} = \beta^{(k)} + \alpha_k (X^T W^{(k)} X)^{-1} X^T W^{(k)} \mathbf{z}^{(k)}. \quad (2.18)$$

En pratique, l'algorithme teste d'abord le pas complet de Newton ($\alpha_k = 1$). Si la fonction de coût augmente (ce qui signale un dépassement), le pas est divisé par deux (procédure de *step-halving*, qui constitue d'ailleurs la routine de sécurité interne de la fonction `glm` du langage R) jusqu'à observer une diminution stricte. Cette stratégie hybride est idéale : elle garantit la **convergence globale** d'après Nocedal et Wright [7, Théorème 3.5] (grâce à l'amortissement lors des premières itérations) tout en recouvrant la vitesse de convergence locale quadratique « fulgurante » de Newton dès que l'on entre dans le bassin d'attraction de l'optimum (où le pas unitaire $\alpha_k = 1$ est systématiquement validé en vertu du théorème 3.6, permettant de recouvrer la convergence quadratique établie par le théorème 3.5 de l'ouvrage de Nocedal et Wright [7]).

2.2.4 Pseudo-Code

La procédure complète, telle qu'implémentée dans les algorithmes de production (incluant l'amortissement), se déroule ainsi :

1. **Initialisation** : Fixer $\beta^{(0)}$ (souvent à 0) et évaluer le coût initial $J(\beta^{(0)})$.
2. **Boucle itérative** : À l'étape k , tant que la convergence n'est pas atteinte :
 - Calculer le prédicteur linéaire $\eta_i^{(k)} = x_i^T \beta^{(k)}$ et les probabilités $p_i^{(k)} = \pi(x_i^T \beta^{(k)})$.
 - Calculer la matrice diagonale des poids $W^{(k)}$ de terme général $w_{i,i}^{(k)} = p_i^{(k)}(1 - p_i^{(k)})$.
 - Construire la variable de travail ajustée : $z_i^{(k)} = \eta_i^{(k)} + \frac{y_i - p_i^{(k)}}{p_i^{(k)}(1 - p_i^{(k)})}$.
 - Régresser $\mathbf{z}^{(k)}$ sur X avec la matrice de poids $W^{(k)}$ pour obtenir le candidat de Newton pur $\tilde{\beta}$.
 - Définir la direction de mise à jour : $\Delta\beta^{(k)} = \tilde{\beta} - \beta^{(k)}$.
 - **Recherche linéaire (*Step-halving*)** : Initialiser le pas $\alpha = 1$.
 - Tant que $J(\beta^{(k)} + \alpha\Delta\beta^{(k)}) > J(\beta^{(k)})$, réduire le pas géométriquement : $\alpha \leftarrow \alpha/2$.
 - Valider la mise à jour : $\beta^{(k+1)} = \beta^{(k)} + \alpha\Delta\beta^{(k)}$.
3. **Arrêt** : Lorsque la variation des coefficients $\|\beta^{(k+1)} - \beta^{(k)}\|$ est inférieure à un seuil ϵ (typiquement 10^{-8}).

2.2.5 Stabilité Numérique et Décomposition QR

D'un point de vue purement mathématique, la direction de Newton s'écrit de manière analytique :

$$\Delta\beta^{(k)} = -[\nabla^2 J(\beta^{(k)})]^{-1} \nabla J(\beta^{(k)}). \quad (2.19)$$

Cependant, en analyse numérique, l'inversion explicite de la matrice Hessienne $\nabla^2 J(\beta^{(k)}) = X^T W^{(k)} X$ est une pratique à proscrire. Si les variables explicatives présentent une forte colinéarité, la matrice $\nabla^2 J(\beta^{(k)})$ devient mal conditionnée (son déterminant s'approche de zéro). L'inversion directe amplifie alors de manière catastrophique les erreurs d'arrondi en virgule flottante.

Pour garantir une robustesse dans les implémentations informatiques, on ne calcule jamais $[\nabla^2 J(\beta^{(k)})]^{-1}$. On traite le calcul de la direction comme la résolution du système d'équations linéaires suivant :

$$\nabla^2 J(\beta^{(k)}) \Delta \beta^{(k)} = -\nabla J(\beta^{(k)}). \quad (2.20)$$

Ce système est résolu à l'aide d'une **Décomposition QR** (factorisation de Householder). Cette méthode décompose la matrice en un produit d'une matrice orthogonale Q et d'une matrice triangulaire supérieure R , permettant de trouver le vecteur de direction optimal $\Delta \beta^{(k)}$ avec une stabilité numérique maximale, même aux limites de la singularité. Outre la multicolinéarité, cette précaution numérique permet également de pallier le problème de saturation des probabilités (lorsque $p_i(\beta) \rightarrow 0$ ou 1, annulant les éléments diagonaux $w_{i,i}^{(k)} = p_i(1 - p_i)$).

2.2.6 Comparaison Algorithmique : Gradient et Newton-Raphson

À ce stade du développement, il convient de définir le domaine de pertinence de chaque approche afin d'orienter le choix de la méthode selon la nature des données :

- **Descente de Gradient** : Indispensable pour les problèmes de haute dimension ou les très grands volumes de données, où le coût de calcul et de factorisation de la Hessienne (en $O(np^2 + p^3)$) est prohibitif. C'est l'algorithme moteur des réseaux de neurones et du Deep Learning.
- **Newton-Raphson (IRLS)** : À privilégier pour les problèmes de taille modérée ($p < 1000$) et lorsque l'inférence statistique précise est requise. La courbure (Hessienne) fournit naturellement les écarts-types des estimateurs via la matrice de Fisher inverse comme nous le verrons dans le Chapitre 3.

2.3 Méthode de Second Ordre Approché : Quasi-Newton (BFGS)

Les sections précédentes ont mis en évidence un dilemme fondamental en optimisation numérique pour la régression logistique :

- La descente de gradient (Section 2.1) a un coût par itération très faible $\mathcal{O}(p)$, mais converge lentement (linéairement) car elle ignore la courbure de la fonction.
- La méthode de Newton-Raphson (Section 2.2) converge très vite (quadratiquement) mais requiert le calcul exact de la Hessienne $H(\beta)$ et la résolution du système linéaire associé, des opérations d'une complexité algorithmique cubique en $\mathcal{O}(p^3)$.

Les méthodes de **Quasi-Newton** constituent le compromis optimal pour les problèmes de dimension moyenne à grande ($100 < p < 10000$). L'idée centrale est de remplacer la Hessienne exacte par une matrice d'approximation B_k qui est mise à jour itérativement à partir des informations de gradient, sans jamais nécessiter de recalcul complet ni d'inversion coûteuse.

L'algorithme de référence dans cette catégorie est l'algorithme **BFGS** (Broyden-Fletcher-Goldfarb-Shanno).

2.3.1 Le Principe de la Condition Sécante

Rappelons que nous cherchons à minimiser la fonction de coût $J(\beta)$, définie comme l'opposé de la log-vraisemblance :

$$J(\beta) = -\ell(\beta).$$

L'objectif est de construire une matrice $B^{(k+1)}$ qui imite le comportement de la vraie Hessienne $\nabla^2 J(\beta)$ au voisinage de la solution. Considérons le développement de Taylor du gradient au premier

ordre autour de l'itération courante $\beta^{(k)}$:

$$\nabla J(\beta^{(k+1)}) \approx \nabla J(\beta^{(k)}) + \nabla^2 J(\beta^{(k)})(\beta^{(k+1)} - \beta^{(k)}). \quad (2.21)$$

Si $B^{(k+1)}$ est une bonne approximation de la Hessienne, elle doit satisfaire cette relation d'égalité pour les points observés. Définissons les vecteurs de déplacement :

- Le pas dans l'espace des paramètres : $\mathbf{s}^{(k)} = \beta^{(k+1)} - \beta^{(k)}$
- Le changement du gradient : $\mathbf{q}^{(k)} = \nabla J(\beta^{(k+1)}) - \nabla J(\beta^{(k)})$

L'approximation $B^{(k+1)}$ doit satisfaire la **Condition Sécante** (ou équation de Quasi-Newton) :

$$B^{(k+1)}\mathbf{s}^{(k)} = \mathbf{q}^{(k)}. \quad (2.22)$$

Cette équation signifie que la matrice $B^{(k+1)}$ doit correctement transformer le déplacement des paramètres en changement de gradient, capturant ainsi la courbure moyenne sur le pas effectué.

2.3.2 Approximation Directe de l'Inverse de la Hessienne

Dans la méthode de Newton (IRLS), la direction de descente $\mathbf{d}^{(k)}$ est obtenue en résolvant le système linéaire $\nabla^2 J(\beta^{(k)})\mathbf{d}^{(k)} = -\nabla J(\beta^{(k)})$. Bien que ce système soit résolu numériquement de manière stable (via la décomposition QR détaillée à la section précédente), cette étape impose inévitablement un coût lourd de $\mathcal{O}(p^3)$ opérations.

L'astuce fondamentale des méthodes de Quasi-Newton, et spécifiquement de BFGS, est de contourner totalement cette résolution de système. Au lieu d'approximer la matrice Hessienne elle-même, l'algorithme construit et met à jour itérativement une matrice $D^{(k)}$ qui approxime directement l'opérateur inverse de la Hessienne :

$$D^{(k)} \approx \left(\nabla^2 J(\beta^{(k)}) \right)^{-1}. \quad (2.23)$$

Grâce à cette matrice $D^{(k)}$, le calcul de la direction de descente $\mathbf{d}^{(k)}$ ne nécessite plus aucune résolution de système, mais se réduit à une simple multiplication matricielle (de coût $\mathcal{O}(p^2)$) :

$$\mathbf{d}^{(k)} = -D^{(k)}\nabla J(\beta^{(k)}). \quad (2.24)$$

Il reste à déterminer comment mettre à jour cette matrice $D^{(k)}$ pour qu'elle respecte la géométrie de la fonction. Reprenons la condition sécante établie précédemment pour la Hessienne ($B^{(k+1)}\mathbf{s}^{(k)} = \mathbf{q}^{(k)}$). En multipliant cette équation à gauche par la matrice inverse $D^{(k+1)} = (B^{(k+1)})^{-1}$, nous obtenons directement la relation :

$$\mathbf{s}^{(k)} = D^{(k+1)}\mathbf{q}^{(k)}. \quad (2.25)$$

C'est cette équation, appelée **condition sécante pour l'inverse**, que la matrice $D^{(k+1)}$ devra satisfaire pour garantir que notre approximation de la courbure reste cohérente avec les observations du gradient.

2.3.3 La Formule de Mise à Jour BFGS

La construction de la matrice $D^{(k+1)}$ repose sur une approche itérative plutôt que sur un recalcul global. Le principe consiste à **corriger** l'estimation précédente $D^{(k)}$ en y intégrant la nouvelle information de courbure récoltée via le couple $(\mathbf{s}^{(k)}, \mathbf{q}^{(k)})$.

La formule de mise à jour BFGS, considérée comme la plus robuste de l'état de l'art d'après Nocedal et Wright [7, Section 6.1], procède par une « correction de rang 2 ». Elle correspond à la solution

analytique du problème de minimisation de la distance (en norme de Frobenius pondérée) entre $D^{(k+1)}$ et $D^{(k)}$, sous la contrainte stricte de l'équation sécante inverse (2.25) (voir démonstration détaillée en **Annexe A.9**).

La formule est la suivante :

$$D^{(k+1)} = \left(I - \rho^{(k)} \mathbf{s}^{(k)} (\mathbf{q}^{(k)})^T \right) D^{(k)} \left(I - \rho^{(k)} \mathbf{q}^{(k)} (\mathbf{s}^{(k)})^T \right) + \rho^{(k)} \mathbf{s}^{(k)} (\mathbf{s}^{(k)})^T \quad (2.26)$$

avec le scalaire de normalisation $\rho^{(k)} = \frac{1}{(\mathbf{q}^{(k)})^T \mathbf{s}^{(k)}}$.

La structure de cette équation révèle une mécanique de mise à jour géométrique en deux étapes complémentaires :

- Le premier terme (le produit avec les matrices identité I) sert à « nettoyer » l'ancienne matrice $D^{(k)}$ en supprimant les informations obsolètes dans la direction du mouvement.
- Le second terme $(+\rho^{(k)} \mathbf{s}^{(k)} (\mathbf{s}^{(k)})^T)$ injecte la nouvelle courbure observée durant le pas.

Cette structure garantit une propriété cruciale : si la matrice initiale $D^{(0)}$ est définie positive (par exemple la matrice identité), alors toutes les matrices suivantes $D^{(k)}$ le seront aussi. Cela assure que l'algorithme générera toujours des directions de descente valides, sans jamais remonter la pente.

2.3.4 Initialisation et Pseudo-Code

Pour que la relation de récurrence (2.26) soit opérationnelle, il est nécessaire de définir une matrice initiale $D^{(0)}$. En l'absence d'information préalable sur la courbure, le choix standard est la **matrice identité** :

$$D^{(0)} = I_p.$$

Cela implique que la première itération de l'algorithme BFGS correspond à un pas de descente de gradient classique. La matrice $D^{(k)}$ s'enrichit ensuite progressivement des informations de courbure au fil des itérations.

Une condition essentielle pour la convergence est que le produit scalaire $(\mathbf{q}^{(k)})^T \mathbf{s}^{(k)}$ soit strictement positif. Cette condition, dite de courbure, assure que la mise à jour préserve le caractère défini positif de l'approximation de l'inverse de la Hessienne. Dans le cas de la régression logistique, la fonction de coût $J(\beta)$ étant strictement convexe, cette condition est vérifiée pour tout pas non nul.

Voici la structure globale de l'algorithme :

1. **Initialisation** : $\beta^{(0)}, D^{(0)} \leftarrow I_p$, tolérance ϵ .
2. **Tant que** $\|\nabla J(\beta^{(k)})\| > \epsilon$:
 - (a) Calcul de la direction : $\mathbf{d}^{(k)} = -D^{(k)} \nabla J(\beta^{(k)})$.
 - (b) Recherche linéaire (Armijo/Wolfe) : Trouver un pas $\alpha^{(k)}$.
 - (c) Mise à jour des paramètres : $\beta^{(k+1)} = \beta^{(k)} + \alpha^{(k)} \mathbf{d}^{(k)}$.
 - (d) Calcul des variations :
$$\mathbf{s}^{(k)} = \beta^{(k+1)} - \beta^{(k)} \quad \text{et} \quad \mathbf{q}^{(k)} = \nabla J(\beta^{(k+1)}) - \nabla J(\beta^{(k)})$$
 - (e) Mise à jour de la Hessienne inverse $D^{(k+1)}$ via la formule (2.26).
3. **Fin** : Retourner $\beta^{(k)}$.

Note sur le L-BFGS (Limited-memory BFGS) : Pour les problèmes de grande dimension ($p > 10^4$), le stockage de la matrice dense $D^{(k)}$ (contenant p^2 éléments) peut devenir prohibitif. On utilise alors une variante nommée **L-BFGS**, décrite par Nocedal et Wright [7, Section 7.2], qui ne stocke pas la matrice explicitement. L'algorithme conserve uniquement les m derniers couples de vecteurs $(\mathbf{s}^{(i)}, \mathbf{q}^{(i)})$ afin de calculer le produit $D^{(k)} \nabla J(\beta^{(k)})$ par une procédure récursive à moindre coût mémoire.

2.3.5 Analyse de Complexité et Convergence

La méthode BFGS présente des propriétés théoriques qui en font le choix algorithmique par défaut dans les bibliothèques d'optimisation standards (telles que la fonction `optim` en R ou `scipy.optimize` en Python) :

1. **Complexité Algorithmique** : Chaque itération nécessite $\mathcal{O}(p^2)$ opérations (multiplication matrice-vecteur), contre $\mathcal{O}(p^3)$ pour la méthode de Newton. Ce gain de performance devient déterminant lorsque le nombre de prédicteurs p augmente.
2. **Vitesse de Convergence** : La méthode bénéficie d'une convergence **super-linéaire**, formellement démontrée par Nocedal et Wright [7, Section 6.4] :

$$\lim_{k \rightarrow \infty} \frac{\|\beta^{(k+1)} - \beta^*\|}{\|\beta^{(k)} - \beta^*\|} = 0.$$

Algorithmiquement, cette propriété indique que le taux de contraction de l'erreur s'accélère asymptotiquement à l'approche de l'optimum β^* .

3. **Robustesse** : Contrairement à la méthode de Newton qui requiert une Hessienne définie positive à chaque étape (ce qui est vérifié pour la log-vraisemblance de la régression logistique, mais pas pour toute fonction cible non-convexe), l'algorithme BFGS maintient la propriété définie positive de l'approximation $D^{(k)}$ par construction. Cela assure que $\mathbf{d}^{(k)}$ demeure systématiquement une direction de descente.

En synthèse, le choix de l'algorithme d'optimisation pour l'ajustement d'un modèle de régression logistique s'oriente selon la dimensionnalité du problème :

- Si n est grand et p modéré ($p < 100$) : L'algorithme de Newton-Raphson (IRLS) est privilégié pour sa précision statistique (le calcul exact de la Hessienne fournissant directement la matrice de variance-covariance des estimateurs).
- Si p est élevé ($p > 100$) : La méthode BFGS (ou L-BFGS) s'impose comme le compromis optimal entre coût matriciel et vitesse de convergence.
- Si n et p sont massifs : L'optimisation par descente de Gradient Stochastique (SGD) ou ses variantes par mini-lots constituent un recours viable.

Chapitre 3

Propriétés Asymptotiques et Inférence Statistique

L'estimation ponctuelle des paramètres $\hat{\beta}$ obtenue via les algorithmes d'optimisation du Chapitre 2 ne constitue qu'une première étape. Pour établir les propriétés statistiques du modèle de régression logistique, il est impératif d'évaluer l'incertitude de ces estimations. Ce chapitre établit le cadre rigoureux de l'inférence statistique, justifiant le passage d'une simple minimisation algorithmique à la validation d'hypothèses.

3.1 Normalité Asymptotique de l'Estimateur

3.1.1 L'Information de Fisher : Mesure géométrique de l'incertitude

La théorie asymptotique du Maximum de Vraisemblance repose sur un principe géométrique : la courbure de la fonction de log-vraisemblance évaluée à son maximum détermine la précision de l'estimation. Une courbure prononcée indique qu'une faible déviation par rapport au maximum entraîne une chute rapide de la vraisemblance, ce qui se traduit par une faible variance de l'estimateur. À l'inverse, une courbure aplatie indique que de nombreuses valeurs expliquent tout aussi bien les données, traduisant une forte incertitude.

Cette courbure locale est quantifiée par la matrice d'Information de Fisher, un concept fondateur de la théorie asymptotique détaillé notamment par McCullagh et Nelder [2, Section 4.4].

Information de Fisher théorique : L'Information de Fisher théorique représente la variance du score et quantifie l'information apportée par les observations sur les paramètres à estimer. Dans notre modèle de régression logistique paramétré par β , où la variable Y est conditionnée par X , elle correspond formellement à l'opposé de l'espérance conditionnelle de la matrice Hessienne de la log-vraisemblance :

$$\mathcal{I}(\beta) = -\mathbb{E}_{Y|X} [\nabla^2 \ell(\beta)] . \quad (3.1)$$

Nous avons par ailleurs établi que la matrice Hessienne de la log-vraisemblance $\nabla \ell(\beta)$ s'écrit $\nabla^2 \ell(\beta) = H(\beta) = -X^T W(\beta) X$, où $W(\beta)$ est la matrice diagonale des variances locales $w_{i,i}(\beta) = p_i(\beta)(1 - p_i(\beta))$. Fait remarquable de la régression logistique : la variable aléatoire Y disparaît totalement lors de la seconde dérivation. La matrice Hessienne ne dépend plus que des variables explicatives X et des probabilités $p(\beta)$. Le raisonnement s'effectuant conditionnellement à X (traitée comme fixe), cette matrice est donc purement déterministe vis-à-vis de la distribution de Y .




FIGURE 3.1 – Illustration de l’Information de Fisher. Un pic étroit (courbure forte) correspond à une variance faible de l’estimateur $\hat{\beta}$. Une vallée large (courbure faible) indique une forte incertitude.

Ainsi, l’espérance conditionnelle de la Hessienne coïncide avec la Hessienne empirique. De ce fait, Rakotomalala [1] rappelle que pour le modèle logit, l’Information de Fisher **observée** (évaluée sur l’échantillon) et l’Information de Fisher **théorique** sont rigoureusement équivalentes :

$$\mathcal{I}(\beta) = X^T W(\beta) X. \quad (3.2)$$

Dans la section suivante, nous verrons que la construction des tests d’inférence nécessite impérativement que cette matrice $\mathcal{I}(\beta)$ soit inversible.

Or, comme démontré au Chapitre 1 (section *Du Rang Plein à l’Unicité*), la matrice Hessienne $H(\beta)$ est définie négative dès lors que la matrice d’expérience X est de plein rang et que les probabilités $p_i(\beta)$ n’atteignent jamais les bornes exactes 0 ou 1. Puisque l’Information de Fisher est l’opposée exacte de la matrice Hessienne, nos hypothèses du modèle garantissent que $\mathcal{I}(\beta)$ est définie positive, et par conséquent, inversible.

Selon les travaux d’Albert et Anderson [4], cette condition de non-dégénérescence des probabilités est satisfaite si et seulement s’il existe un chevauchement strict entre les classes. Ainsi, la configuration topologique qui garantissait l’existence de l’EMV $\hat{\beta}$ est exactement celle qui rend l’Information de Fisher inversible, autorisant de ce fait la réalisation des tests statistiques.

3.1.2 Convergence en Loi et Variance Asymptotique

Pour établir la normalité asymptotique de l’Estimateur du Maximum de Vraisemblance $\hat{\beta}$, le modèle doit satisfaire les conditions de régularité de Fisher. Comme formalisé par McCullagh et Nelder [2, Section 4.4], la distribution de Bernoulli appartient à la famille exponentielle, dont la fonction logit constitue le lien canonique (la démonstration algébrique complète de cette identification est détaillée en **Annexe A.10**). Grâce à cette appartenance, les critères de régularité sont naturellement vérifiés :

1. **Support indépendant** : Le support de la variable observable Y est l’ensemble $\{0, 1\}$, un espace discret fixe qui ne dépend pas du vecteur de paramètres β .
2. **Identifiabilité** : Le paramètre β est identifiable grâce au rang plein de la matrice X (Hypothèse 2), garantissant l’injectivité de l’application $\beta \mapsto X\beta$.

3. **Régularité analytique** : La fonction de log-vraisemblance (composée de polynômes et de logarithmes définis sur $]0, 1[$) est infiniment dérivable sur son domaine (de classe $\mathcal{C}^\infty$). De plus, le support de la distribution étant indépendant de β , le théorème de convergence dominée de Lebesgue autorise l'interversion des opérateurs d'intégration (ou de sommation) et de dérivation, ce qui est indispensable pour calculer les moments du score.

4. **Information définie positive** : La matrice d'Information de Fisher $\mathcal{I}(\beta)$ est définie positive en tout point, condition validée à la section précédente par la présence d'un chevauchement.

Ces conditions étant réunies, la théorie générale du Maximum de Vraisemblance établit la convergence en loi de l'estimateur. Lorsque la taille de l'échantillon n tend vers l'infini, l'estimateur $\hat{\beta}$ converge en probabilité vers la vraie valeur du paramètre β et suit asymptotiquement une loi Normale multivariée. Sa matrice de variance-covariance correspond exactement à l'inverse de l'Information de Fisher :

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, \mathcal{I}_1^{-1}(\beta)) \quad (3.3)$$

où $\mathcal{I}_1(\beta)$ désigne la matrice d'Information de Fisher théorique apportée par une seule observation. En pratique, pour un échantillon fini de taille n , l'inférence repose sur la variance totale estimée. Comme démontré en détail dans l'**Annexe A.11** (en s'appuyant sur le développement de Taylor du vecteur Score et le théorème de Slutsky), l'approximation asymptotique de la distribution de l'estimateur s'écrit alors :

$$\left(X^T W(\hat{\beta}) X\right)^{1/2} (\hat{\beta} - \beta) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, I_{p+1}) \quad (3.4)$$

où I_{p+1} désigne la matrice identité d'ordre $p + 1$. De manière équivalente, nous avons :

$$\hat{\beta} \sim \mathcal{N}\left(\beta, (X^T W(\hat{\beta}) X)^{-1}\right). \quad (3.5)$$

Remarque algorithmique : Ce résultat statistique met en lumière un avantage pratique majeur de la méthode de Newton-Raphson (IRLS) présentée au Chapitre 2. Pour calculer sa direction de descente, cet algorithme construit systématiquement la matrice Hessienne de la fonction de coût $\nabla^2 J(\beta) = X^T W(\beta) X$. Même si la stabilité numérique (via la décomposition QR) nous évite de l'inverser à chaque étape, cette matrice est déjà entièrement calculée lorsque l'algorithme atteint le minimum $\hat{\beta}$. Il suffit alors de l'inverser une seule fois à la toute fin pour obtenir la matrice de variance-covariance asymptotique $(X^T W(\hat{\beta}) X)^{-1}$. En comparaison, les méthodes du premier ordre (telles que la Descente de Gradient) n'évaluent jamais l'inverse de cette Hessienne durant leur exécution. L'obtention de la matrice de variance-covariance nécessite alors de programmer et d'exécuter cette coûteuse opération d'inversion matricielle a posteriori, une fois le modèle entraîné, uniquement à des fins d'inférence.

3.2 Tests d'Hypothèses et Significativité

3.2.1 Le Test de Wald

Une fois la distribution asymptotique de l'Estimateur du Maximum de Vraisemblance établie, il devient possible d'évaluer statistiquement l'impact de chaque variable explicative. La question centrale est de savoir si le coefficient β_j , associé à la j -ème variable du modèle, est significativement différent de zéro.

Il s'agit d'un test de significativité paramétrique. L'outil privilégié dans le cadre des modèles linéaires généralisés pour éprouver cette significativité est le test de Wald, dont les propriétés sont détaillées

par McCullagh et Nelder [2, Section 4.4.4]. La démarche s'articule selon la procédure classique des tests d'hypothèses :

Formulation des hypothèses :

- **Hypothèse nulle** (H_0) : Le coefficient est nul ($\beta_j = 0$). La j -ème variable n'a pas d'effet propre sur la prédiction, conditionnellement aux autres variables du modèle.
- **Hypothèse alternative** (H_1) : Le coefficient est différent de zéro ($\beta_j \neq 0$). La j -ème variable apporte une contribution statistiquement significative au modèle (test bilatéral).

Statistique de test et loi limite : Sous l'hypothèse nulle H_0 , lorsque $\beta_j = 0$, la statistique de test Z se construit en rapportant la valeur estimée du paramètre à son erreur-type asymptotique estimée :

$$Z = \frac{\hat{\beta}_j}{\widehat{SE}(\hat{\beta}_j)}. \quad (3.6)$$

Dans cette expression, l'erreur standard $\widehat{SE}(\hat{\beta}_j)$ correspond à la racine carrée du j -ème élément diagonal de la matrice de variance-covariance estimée. En reprenant l'expression de l'Information de Fisher établie précédemment, nous avons formellement : $\widehat{SE}(\hat{\beta}_j) = \sqrt{[(X^T W(\hat{\beta}) X)^{-1}]_{jj}}$.

Sous l'hypothèse nulle H_0 , lorsque la taille de l'échantillon n tend vers l'infini, on a la convergence en loi suivante :

$$Z \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1). \quad (3.7)$$

Région critique : Soit $\alpha \in]0, 1[$. Avec un risque de première espèce α (conventionnellement fixé à 0.05), on accepte l'hypothèse alternative $\mathcal{H}^1$ dès que :

$$|Z| > z_{1-\alpha/2} \quad (3.8)$$

où $z_{1-\alpha/2}$ représente le quantile d'ordre $1 - \alpha/2$ d'une loi normale centrée réduite $\mathcal{N}(0, 1)$.

Décision et conclusion : Soit Z^{exp} la valeur expérimentale de la statistique Z . Si $|Z^{exp}| > z_{1-\alpha/2}$, on accepte l'hypothèse alternative $\mathcal{H}^1$. On conclut alors que la j -ème variable apporte une contribution statistiquement significative au modèle, conditionnellement aux autres variables. Dans le cas contraire, on conserve H_0 (le modèle ne dispose pas de preuves statistiques suffisantes pour affirmer que le coefficient est non nul).

p-valeur : La p-valeur représente le plus petit seuil α pour lequel on peut rejeter l'hypothèse nulle. Dans ce cadre bilatéral, la p-valeur est la probabilité :

$$\text{p-valeur} = 2 \times \mathbb{P}(Z \geq |Z^{exp}|) \quad (3.9)$$

où Z est une variable aléatoire suivant une loi $\mathcal{N}(0, 1)$ sous l'hypothèse nulle. Si cette p-valeur est inférieure au seuil α , l'hypothèse nulle est rejetée. Ce cas de figure revêt une importance capitale lors de la confrontation du modèle aux données réelles, comme nous l'illustrerons au Chapitre 4.

3.2.2 Limites du Test de Wald : Le Paradoxe de Hauck-Donner

Bien que le test de Wald soit le standard implémenté par défaut dans la majorité des logiciels statistiques pour évaluer la significativité individuelle des coefficients, il souffre d'une vulnérabilité mathématique sévère identifiée par Hauck et Donner [9, Chapitre 1].

Ce phénomène se manifeste paradoxalement lorsque la capacité de discrimination d'une variable explicative est excellente (c'est-à-dire lorsqu'on s'approche d'une situation de séparation parfaite des données). Dans un tel scénario, la valeur absolue du coefficient estimé $\hat{\beta}_j$ devient très grande. Or, comme nous l'avons analysé au Chapitre 2, cette augmentation pousse les probabilités prédites vers les bornes de saturation (0 ou 1). La variance locale $w_{i,i}(\hat{\beta}) = p_i(\hat{\beta})(1 - p_i(\hat{\beta}))$ s'effondre alors vers zéro.

Par conséquent, la matrice d'Information de Fisher se vide de son information, et son inverse (qui définit la variance de l'estimateur) explose. Le paradoxe de Hauck-Donner réside dans le fait que l'erreur standard (le dénominateur de la statistique de Wald) tend vers l'infini beaucoup plus rapidement que le coefficient lui-même (le numérateur).

Ainsi, la valeur expérimentale de la statistique de test s'effondre :

$$\lim_{|\hat{\beta}_j| \rightarrow +\infty} Z^{exp} = \lim_{|\hat{\beta}_j| \rightarrow +\infty} \frac{\hat{\beta}_j}{\widehat{SE}(\hat{\beta}_j)} = 0. \quad (3.10)$$

La p-valeur remonte alors artificiellement vers 1. Le test échoue de manière aberrante à rejeter l'hypothèse nulle, déclarant "non significative" une variable qui sépare pourtant presque parfaitement les deux classes.

Face à cette instabilité numérique de la variance asymptotique, particulièrement critique sur les petits échantillons, la théorie statistique moderne recommande formellement de privilégier le **Test du Rapport de Vraisemblance** (LRT, détaillé à la Section 3.4), qui compare directement les déviations sans nécessiter l'inversion de la matrice d'Information de Fisher.

3.3 Interprétation des Coefficients : L'Odds Ratio

3.3.1 Des Probabilités aux Cotes (Odds)

Dans un modèle de régression linéaire classique, le coefficient β_j s'interprète directement comme la variation marginale de la variable d'intérêt Y pour une augmentation d'une unité de la j -ème variable explicative. Dans le cadre de la régression logistique, la présence de la fonction de lien non linéaire (la fonction logit) rend cette interprétation additive directe impossible.

Pour redonner un sens aux paramètres estimés, la littérature statistique s'appuie sur la notion de cote (ou *odds*). Soit $p_i = \mathbb{P}(y_i = 1|x_i)$ la probabilité de succès. La cote est définie comme le rapport entre la probabilité que l'événement se réalise et la probabilité qu'il ne se réalise pas :

$$\text{Cote}_i = \frac{p_i}{1 - p_i}. \quad (3.11)$$

Par définition du modèle logit (cf. Chapitre 1), le logarithme népérien de cette cote est une combinaison linéaire des variables explicatives. On obtient ainsi la relation fondamentale suivante :

$$\ln\left(\frac{p_i}{1 - p_i}\right) = x_i^T \beta \quad \Longleftrightarrow \quad \text{Cote}_i = \exp(x_i^T \beta). \quad (3.12)$$

3.3.2 Définition et Calcul de l'Odds Ratio

L'Odds Ratio (OR), ou rapport de cotes, permet de quantifier l'effet multiplicatif propre à chaque variable explicative sur la cote de succès.

Pour isoler l'Odds Ratio associé spécifiquement au coefficient β_j , noté OR_j , la démarche consiste à comparer deux observations. Considérons deux individus x_a et x_b dont l'ensemble des caractéristiques sont strictement identiques, à l'exception de la j -ème composante pour laquelle l'individu b présente une unité de plus que l'individu a ($x_{b,j} = x_{a,j} + 1$). Le rapport des cotes entre ces deux individus s'écrit :

$$OR_j = \frac{\text{Cote}(x_b)}{\text{Cote}(x_a)} = \frac{\exp(\beta_0 + \beta_1 x_{a,1} + \cdots + \beta_j(x_{a,j} + 1) + \cdots + \beta_p x_{a,p})}{\exp(\beta_0 + \beta_1 x_{a,1} + \cdots + \beta_j x_{a,j} + \cdots + \beta_p x_{a,p})}. \quad (3.13)$$

Par les propriétés algébriques élémentaires de la fonction exponentielle, les termes associés aux variables identiques au numérateur et au dénominateur se simplifient. Rakotomalala [1] souligne que cette factorisation conduit à une simplification remarquable, isolant l'effet du paramètre :

$$OR_j = \exp(\beta_j). \quad (3.14)$$

L'estimation ponctuelle de l'Odds Ratio se déduit donc de l'Estimateur du Maximum de Vraisemblance (EMV) par une simple transformation exponentielle : $\widehat{OR}_j = \exp(\hat{\beta}_j)$.

Critère d'interprétation : L'Odds Ratio centre son interprétation autour de la valeur neutre 1. Puisque la cote est une fonction strictement croissante de la probabilité, l'interprétation peut se formuler directement en termes de probabilité de succès (l'événement $Y = 1$) :

- Si $\exp(\hat{\beta}_j) > 1$ (soit $\hat{\beta}_j > 0$) : La j -ème variable accroît la probabilité de succès. Elle constitue un facteur favorisant (ou facteur de risque).
- Si $\exp(\hat{\beta}_j) < 1$ (soit $\hat{\beta}_j < 0$) : La j -ème variable réduit la probabilité de succès. Elle constitue un facteur protecteur.
- Si $\exp(\hat{\beta}_j) = 1$ (soit $\hat{\beta}_j = 0$) : La j -ème variable n'exerce aucun effet multiplicatif sur les cotes, et laisse donc la probabilité de succès inchangée. Cela correspond à l'hypothèse nulle H_0 du test de Wald.

3.3.3 Intervalle de Confiance de l'Odds Ratio

Puisque l'estimation ponctuelle $\widehat{OR}_j$ est sujette aux fluctuations d'échantillonnage, il est rigoureusement indispensable de lui associer un intervalle de confiance pour valider sa pertinence populationnelle.

À la Section 3.2, nous avons établi que la statistique de test $Z = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}$ convergeait en loi vers $\mathcal{N}(0, 1)$. On en déduit l'intervalle de confiance asymptotique de niveau $1 - \alpha$ pour le paramètre brut β_j :

$$IC_{1-\alpha}(\beta_j) = \left[\hat{\beta}_j - z_{1-\alpha/2} \widehat{SE}(\hat{\beta}_j) ; \hat{\beta}_j + z_{1-\alpha/2} \widehat{SE}(\hat{\beta}_j) \right]. \quad (3.15)$$

La fonction exponentielle étant une bijection strictement croissante sur $\mathbb{R}$, elle conserve l'ordre des inégalités. Par conséquent, l'intervalle de confiance de l'Odds Ratio s'obtient par la transformation directe des bornes de l'intervalle de β_j :

$$IC_{1-\alpha}(OR_j) = \left[\exp\left(\hat{\beta}_j - z_{1-\alpha/2} \widehat{SE}(\hat{\beta}_j)\right) ; \exp\left(\hat{\beta}_j + z_{1-\alpha/2} \widehat{SE}(\hat{\beta}_j)\right) \right]. \quad (3.16)$$

Il convient de noter une propriété géométrique induite par cette transformation : si l'intervalle de confiance de β_j est parfaitement symétrique par construction, celui de l'Odds Ratio est intrinsèquement asymétrique autour de son estimation ponctuelle $\widehat{\text{OR}}_j$, la courbure de l'exponentielle étirant la borne supérieure.

Cette construction boucle l'architecture de l'inférence statistique locale. Elle présente une dualité parfaite avec le test de significativité : si l'intervalle de confiance $IC_{1-\alpha}(\text{OR}_j)$ contient la valeur neutre 1, cela implique directement que le test de Wald associé à ce coefficient ne permet pas d'accepter l'hypothèse alternative H_1 au risque α .

3.4 Évaluation et Sélection de Modèles

Jusqu'à présent, notre démarche inférentielle s'est concentrée sur l'évaluation individuelle des variables explicatives via le test de Wald. Cependant, dans une optique de modélisation prédictive ou explicative, il est crucial d'évaluer la performance globale d'un modèle et de disposer d'outils rigoureux pour comparer plusieurs modèles concurrents. Cette étape est particulièrement décisive lorsque l'on cherche à identifier la meilleure combinaison de prédicteurs sans tomber dans le piège du surapprentissage (*overfitting*).

3.4.1 La Déviance et le Test du Rapport de Vraisemblance

En régression linéaire classique, la qualité globale de l'ajustement est mesurée par la somme des carrés des résidus. En régression logistique, l'équivalent naturel issu de la théorie du maximum de vraisemblance est la **déviance**, dont les propriétés fondamentales ont été formalisées par McCullagh et Nelder [2, Section 4.4.3].

La déviance évalue la qualité d'ajustement du modèle en mesurant l'écart entre sa log-vraisemblance maximisée, notée $\ell(\hat{\beta})$, et celle d'un modèle de référence dit « saturé », notée ℓ_{sat} . Ce modèle saturé est le modèle le plus complexe possible : en allouant un paramètre par observation, il ajuste parfaitement les données (les probabilités estimées sont strictement égales aux réponses observées, $\hat{p}_i = y_i$). Il représente ainsi la borne supérieure de la log-vraisemblance pour le jeu de données étudié. La déviance est formellement définie par :

$$D = -2 \left(\ell(\hat{\beta}) - \ell_{\text{sat}} \right). \quad (3.17)$$

Il est fondamental de noter que dans ce cadre précis de données individuelles binomiales ($y_i \in \{0, 1\}$), la vraisemblance de ce modèle saturé d'ajustement parfait est exactement égale à 1, ce qui implique que sa log-vraisemblance est nulle ($\ell_{\text{sat}} = 0$). Dans la pratique calculatoire, l'expression de la déviance se simplifie donc remarquablement :

$$D = -2\ell(\hat{\beta}). \quad (3.18)$$

Plus la déviance est faible, meilleur est l'ajustement du modèle aux données.

Pour tester la significativité globale du modèle, on effectue un **Test du Rapport de Vraisemblance** (*Likelihood Ratio Test*) en comparant la log-vraisemblance du modèle courant ajusté, $\ell(\hat{\beta})$, à celle d'un modèle dit « vide » ou restreint, notée ℓ_0 .

Ce modèle vide ne contient aucune variable explicative (seule la constante β_0 est estimée). Dans cette configuration, la probabilité prédite est identique pour tous les individus et correspond strictement à la proportion empirique de succès $\bar{p} = \frac{1}{n} \sum_{i=1}^n y_i$ observée dans l'échantillon (et $\hat{\beta}_0 = \ln(\frac{\bar{p}}{1-\bar{p}})$). La log-vraisemblance maximale de ce modèle vide possède donc une forme analytique exacte, ne

dépendant que de la distribution marginale de la variable réponse :

$$\ell_0 = \sum_{i=1}^n [y_i \ln(\bar{p}) + (1 - y_i) \ln(1 - \bar{p})] = n_1 \ln(\bar{p}) + (n - n_1) \ln(1 - \bar{p})$$

où n_1 désigne le nombre total d'observations appartenant à la classe positive ($y_i = 1$).

La statistique de test évaluant l'apport de l'ensemble des variables explicatives s'écrit alors :

$$\Lambda = -2 \left(\ell_0 - \ell(\hat{\beta}) \right). \quad (3.19)$$

Sous l'hypothèse nulle selon laquelle toutes les variables explicatives n'ont aucun effet (tous les $\beta_j = 0$ pour $j \geq 1$), cette statistique suit asymptotiquement une loi du Chi-deux à p degrés de liberté, $\chi^2(p)$. Ce test offre une alternative démontrée comme plus robuste et plus fiable que le test de Wald global pour évaluer l'apport de l'ensemble des variables, comme le recommandent vivement Hosmer et Lemeshow [11, Section 1.3].

3.4.2 Critères d'Information : AIC et BIC

Si l'on cherche à comparer des modèles entre eux (par exemple, pour sélectionner les meilleures variables), la log-vraisemblance (ou la déviance) présente un défaut majeur : elle s'améliore mécaniquement à chaque fois que l'on ajoute une nouvelle variable au modèle, même si celle-ci n'est que du bruit aléatoire. Utiliser la seule log-vraisemblance conduirait inévitablement à sélectionner le modèle le plus complexe.

Pour pallier ce problème, la théorie de l'information introduit des critères pénalisant la complexité du modèle. L'objectif est de trouver le meilleur compromis entre la qualité de l'ajustement aux données et la simplicité du modèle (le principe de parcimonie).

Le Critère d'Information d'Akaike (AIC) : Proposé par Hirotugu Akaike (1974) [12], l'AIC pénalise le modèle proportionnellement au nombre de paramètres estimés k (où $k = p + 1$) :

$$\text{AIC} = -2\ell(\hat{\beta}) + 2k. \quad (3.20)$$

Le modèle préféré est celui qui minimise l'AIC. La pénalité $+2k$ corrige le biais d'optimisme de la log-vraisemblance estimée sur l'échantillon d'apprentissage.

Le Critère d'Information Bayésien (BIC) : Développé par Gideon E. Schwarz (1978) [10], le BIC (ou SBC) introduit une pénalité qui dépend également de la taille de l'échantillon n :

$$\text{BIC} = -2\ell(\hat{\beta}) + k \ln(n). \quad (3.21)$$

Dès que l'échantillon dépasse 7 observations (puisque $\ln(8) > 2$), le BIC pénalise beaucoup plus sévèrement l'ajout de variables que l'AIC. Alors que l'AIC vise à minimiser l'erreur de prédiction asymptotique, le BIC a été conçu pour identifier le modèle génératif parmi les candidats (propriété de consistance), favorisant ainsi des modèles plus compacts et plus directement interprétables.

C'est très exactement ce critère **BIC** que nous privilégierons dans le cadre de notre application pratique (Chapitre 4). Afin d'isoler les meilleurs biomarqueurs parmi les différentes combinaisons de mensurations de la main, la minimisation du BIC nous garantira de ne conserver qu'un ensemble strictement minimal de variables explicatives, assurant ainsi la robustesse statistique de nos conclusions.

Chapitre 4

Applications sur Données Réelles et Évaluation des Algorithmes

L'objectif de ce chapitre est de confronter les développements théoriques des chapitres précédents, tant algorithmiques (Chapitre 2) qu'inférentiels (Chapitre 3) à des cas d'usage empiriques. Afin d'éprouver l'intégralité de notre modélisation, notre démarche s'articule en deux temps :

1. Une analyse statistique approfondie sur un jeu de données biométriques (faible dimension), visant à illustrer la sélection de modèle, l'interprétabilité de l'inférence et la pertinence de l'hyperplan séparateur.
2. Un stress-test algorithmique sur un jeu de données socio-économiques massives et de grande dimension (*Adult Census Income*). Cette seconde phase évalue les limites computationnelles de nos solveurs face à un problème mal conditionné (séparation quasi-complète) et démontre empiriquement la nécessité des méthodes d'optimisation du second ordre.

4.1 Étude Statistique : Modélisation Biométrique de la Main

4.1.1 Présentation du Jeu de Données Biométriques

Avant d'entamer le processus de modélisation, il convient de définir l'espace des données sur lequel reposent nos algorithmes. L'ensemble de données utilisé pour cette étude constitue une source de données primaires : il s'agit de mesures biométriques réelles, relevées et fournies directement dans le cadre de cet encadrement de recherche. Il est à noter que ce jeu de données a servi de base à une publication scientifique récente consacrée aux empreintes de mains dans les grottes ornées [14], ce qui garantit la fiabilité et la précision des mesures.

L'échantillon final est constitué de $n = 81$ individus. La variable cible (la variable à expliquer Y) est le sexe de l'individu, encodé de manière binaire pour répondre aux exigences de la régression logistique :

- $y = 1$ pour la classe « Homme » (la classe positive que l'on cherche à détecter), qui représente 43 observations (soit 53 % de l'échantillon).
- $y = 0$ pour la classe « Femme » (la classe négative), qui représente 38 observations (soit 47 % de l'échantillon).

Cet échantillon s'avère remarquablement équilibré, ce qui valide sur le plan statistique l'utilisation du seuil naturel d'équiprobabilité ($p = 0,5$) pour nos futures matrices de confusion et frontières de décision.

Les variables explicatives (les traits X) collectées pour chaque individu sont des mesures purement géométriques de la main, exprimées en millimètres (mm). Elles comprennent cinq dimensions continues et une variable indicatrice :

- La taille de l'index (le doigt 2D).
- La taille du majeur (le doigt 3D).
- La taille de l'annulaire (le doigt 4D).
- La largeur de la paume.
- La longueur de la paume.
- Le stade de développement biologique (Adulte : Oui / Non).

Bien que collectée lors de la phase d'échantillonnage, cette dernière variable (le stade de développement) a été délibérément exclue du périmètre de la modélisation. L'objectif de cette étude étant d'isoler le pouvoir prédictif de la morphologie et de la géométrie pure de la main, l'inclusion d'un facteur lié à la croissance risquait d'introduire un biais de confusion et de masquer l'influence réelle des proportions telles que l'indice de Manning.

C'est à partir de ces variables morphologiques primaires qu'ont été construits les modèles suivants, d'abord sous forme de ratios empiriques (comme l'indice historique 2D :4D), puis sous une forme brute additive pour laisser notre algorithme d'optimisation sélectionner l'hyperplan séparateur.

4.1.2 Démarche et Sélection des Modèles

L'objectif de cette première application est de tester une hypothèse historique : l'indice de Manning (le ratio entre la longueur de l'index et de l'annulaire, appelé 2D :4D) est-il réellement un bon prédicteur du sexe d'un individu ?

Pour y répondre, nous n'avons pas simplement testé ce ratio de manière isolée. Nous avons mis en place une démarche exploratoire basée sur le Critère d'Information Bayésien (BIC, Section 3.4.2), qui pénalise la complexité des modèles pour ne garder que l'information la plus utile.

Prétraitement des données : Avant de soumettre les variables brutes à nos algorithmes d'optimisation, l'ensemble des mesures continues a été centré et réduit. Cette standardisation est une étape numérique cruciale pour garantir un bon conditionnement de la matrice Hessienne. Par conséquent, lors de l'inférence statistique, l'effet marginal d'une variable (son *Odds Ratio*) correspondra à l'impact d'une augmentation de +1 écart-type, et non d'un millimètre.

Notre raisonnement s'est ensuite articulé autour de trois modèles successifs :

- **Modèle 1 (Le point de référence) :** Ce modèle utilise uniquement l'indice de Manning historique. Il nous sert de base de comparaison.
- **Modèle 2 (Le meilleur ratio possible) :** Nous avons voulu savoir s'il existait un ratio plus performant que celui de Manning. Par une recherche exhaustive de toutes les combinaisons possibles, l'algorithme a identifié que le ratio (Taille de l'Index / Largeur de la Paume) minimisait le BIC.
- **Modèle 3 (L'approche libre) :** Enfin, nous nous sommes demandé s'il était pertinent d'enfermer les variables dans une division (un ratio). En laissant un algorithme d'élimination pas-à-pas (*Stepwise BIC*) sélectionner librement les variables brutes, ce dernier a retenu exactement les deux mêmes variables que le Modèle 2 (Taille de l'Index et Largeur de la Paume), mais de manière additive et indépendante.

Choix d'analyse : Dans la suite de cette étude, nous comparerons principalement le Modèle 1 (l'approche historique) au Modèle 3 (notre approche optimale). Le Modèle 2 a constitué une excellente étape intermédiaire pour prouver que l'indice de Manning n'était pas le meilleur ratio, mais forcer deux variables en une seule fraction détruit de l'information. Le Modèle 3, qui utilise les dimensions pures, s'est révélé nettement meilleur lors de nos tests.

4.1.3 Significativité Globale : Évaluation Comparative des Modèles

Avant d'évaluer l'impact marginal de chaque prédicteur, la robustesse globale de nos approches a été éprouvée via le Test du Rapport de Vraisemblance (LRT), dont le cadre théorique a été formalisé à la Section 3.4. Ce test compare la déviance du modèle ajusté (D) à celle du modèle vide ($D_0 = 111,98$).

L'évaluation du **Modèle 1** (Indice de Manning) révèle une déviance résiduelle de 110,00. La statistique de test correspondante ($\Lambda = 1,98$) est confrontée à une loi du χ^2 à 1 degré de liberté. La p-valeur obtenue ($p = 0,159$) ne permet pas de rejeter l'hypothèse nulle au seuil classique de 5%. Sur le plan biométrique, cela signifie que l'indice de Manning, utilisé de manière isolée, n'apporte pas une quantité d'information globalement significative par rapport à un modèle naïf sans aucun prédicteur. Cette absence de pouvoir prédictif vient directement corroborer les travaux de Ballouard, Cardot et Tardivel [14] menés sur ce même jeu de données. En effet, leur étude démontre, via un test de Wilcoxon-Mann-Whitney (un test d'hypothèse non paramétrique dédié à la comparaison de distributions, particulièrement adaptée aux petits échantillons), que la différence d'indice de Manning entre les sexes n'est pas significative ($p \approx 0,124$).

Le **Modèle 3** (Variables brutes optimales) présente une dynamique radicalement différente. Sa déviance chute de manière spectaculaire pour atteindre 87,06. La statistique du test ($\Lambda = 24,92$), évaluée sur une loi du χ^2 à 2 degrés de liberté, génère une p-valeur extrêmement faible ($p = 3,88 \cdot 10^{-6}$). Ce rejet catégorique de l'hypothèse nulle certifie que la combinaison de la taille de l'index et de la largeur de la paume capte un véritable signal structurel pour la discrimination du sexe. Cette forte significativité conforte pleinement la perspective de recherche soulevée en conclusion de l'étude précitée [14]. Face aux limites des classifieurs univariés, les auteurs y préconisaient d'explorer une approche multivariée. La spécification de notre Modèle 3 valide cette démarche sur le plan explicatif, posant ainsi des bases statistiques solides avant d'en mesurer l'impact concret sur les taux d'erreur de classification dans la suite de notre analyse.

4.1.4 Validation de l'implémentation algorithmique

Afin de garantir l'exactitude du moteur de calcul IRLS développé en C++, une procédure de validation croisée a été menée en comparant les coefficients optimisés par notre algorithme avec ceux issus de la fonction de référence `glm()` du logiciel R.

Le tableau 4.1 présente la comparaison des coefficients β obtenus pour le modèle optimal (Modèle 3).

Variable	β (Algorithme C++)	β (Référence R)	Différence
Intercept	0,1952532	0,1952539	$-7,05 \cdot 10^{-7}$
Taille de l'Index	2,1626641	2,1626738	$-9,66 \cdot 10^{-6}$
Largeur de la Paume	-1,2062989	-1,2063068	$7,94 \cdot 10^{-6}$

TABLE 4.1 – Comparaison des coefficients entre l'implémentation C++ et la bibliothèque standard R.

L'écart maximal observé est de l'ordre de $9,66 \cdot 10^{-6}$. Cette différence infime, située à la sixième décimale, ne résulte pas d'une erreur de calcul mais d'un choix de conception numérique : l'introduction d'une légère régularisation Ridge ($\lambda = 10^{-5}$) dans notre moteur C++ pour stabiliser l'inversion de la matrice Hessienne. La fonction `glm()` standard n'utilisant pas cette pénalité, la convergence vers un optimum légèrement décalé est attendue. Cette identité presque parfaite certifie la précision de notre chaîne de traitement.

4.1.5 Inférence Statistique Locale : Que nous disent les variables ?

Une fois la validité globale établie et nos algorithmes convergés vers le minimum de la fonction de coût, nous avons calculé les p -valeurs (via le test de Wald) et les *Odds Ratios* (OR) pour comprendre l'impact individuel de chaque variable.

Les résultats du **Modèle 1** démontrent que l'indice de Manning n'est pas statistiquement significatif sur notre échantillon ($p = 0.1669$). Son intervalle de confiance à 95 % inclut la valeur 1 ($[0.4602, 1.1436]$), ce qui signifie qu'il est impossible d'affirmer que ce ratio a un véritable effet pour différencier les hommes des femmes ici.

À l'inverse, le **Modèle 3** montre que les variables brutes sont très significatives : la taille de l'index ($p = 0.0001$) et la largeur de la paume ($p = 0.0145$) apportent une véritable information. Plus intéressant encore, l'algorithme a détecté un effet croisé :

- À largeur de paume égale, avoir un index plus long augmente fortement la probabilité d'appartenir à la classe « Homme » (OR = 8.6943).
- À l'inverse, à taille d'index égale, avoir une paume plus large fait chuter cette même probabilité (OR = 0.2993).

Remarque sur l'effet supprimeur : L'impact négatif de la largeur de la paume peut paraître biologiquement contre-intuitif, la morphologie masculine étant généralement associée à des mains plus larges. Ce résultat illustre en réalité un phénomène d'ajustement algébrique propre à la régression multivariée, connu sous le nom d'effet supprimeur. La taille de l'index et la largeur de la paume étant fortement corrélées positivement, la première variable capte la majorité de la variance liée à la grandeur globale de la main. L'algorithme d'optimisation (IRLS) attribue alors un coefficient négatif à la seconde variable non pas pour décrire une caractéristique anatomique féminine, mais pour créer une pénalité géométrique. Cette soustraction permet de corriger la surestimation du Logit induite par la longueur de l'index, affinant ainsi l'hyperplan de séparation avec une précision redoutable.




FIGURE 4.1 – Comparaison des Odds Ratios et de leurs intervalles de confiance à 95 %. Les variables standardisées illustrent l'effet d'une variation de +1 écart-type.

La Figure 4.1 résume cette analyse de manière visuelle. La barre d'erreur du modèle de Manning franchit la ligne pointillée verticale (la ligne de « non-effet »), tandis que les coefficients du Modèle

3 en sont très éloignés, garantissant la fiabilité de l'information trouvée.

4.1.6 Performances de Classification : Les Outils d'Évaluation

Pour évaluer la qualité prédictive de nos modèles, nous avons calculé l'exactitude (Accuracy) en utilisant le seuil de décision standard de 50 % ($p = 0,5$). Sachant que la classe majoritaire (« Homme ») représente 53 % de notre échantillon, un modèle naïf prédisant systématiquement un profil masculin obtiendrait par défaut une exactitude de 53 %. Au regard de ce taux de base naturel, les performances de nos algorithmes s'évaluent ainsi : l'exactitude passe de 59,26 % pour le Modèle 1 (un score à peine supérieur au modèle naïf), à 66,67 % pour le ratio optimal du Modèle 2, jusqu'à atteindre une capacité de discrimination de 70,37 % pour le Modèle 3.

Néanmoins, pour analyser finement ces résultats, nous nous appuyons sur la théorie de l'évaluation des anomalies appliquée à la matrice de confusion. Dans notre cadre, la détection d'un profil masculin constitue l'élément recherché (la classe positive, $y = 1$), et le profil féminin la classe négative ($y = 0$). Les prédictions se décomposent géométriquement en deux ensembles : les **éléments pertinents** (les hommes réels) et les **éléments sélectionnés** (ceux prédits comme hommes par le modèle). L'intersection de ces ensembles forme les Vrais Positifs, tandis que les différences d'ensembles forment les Faux Négatifs et les Faux Positifs.

Conformément à la théorie de l'évaluation, nous analysons nos modèles sous trois prismes :

1. **Le Rappel** : $\frac{\text{Vrais Positifs}}{\text{Vrais Positifs} + \text{Faux Négatifs}}$. C'est la proportion d'éléments pertinents qui ont été effectivement sélectionnés. Autrement dit, sur la liste des hommes réels, combien le modèle a-t-il réussi à en détecter ?
2. **La Spécificité** : $\frac{\text{Vrais Négatifs}}{\text{Vrais Négatifs} + \text{Faux Positifs}}$. C'est la proportion d'éléments non-pertinents qui n'ont pas été sélectionnés. Elle mesure la capacité du modèle à identifier correctement les femmes en évitant de les sélectionner à tort.
3. **La Précision** : $\frac{\text{Vrais Positifs}}{\text{Vrais Positifs} + \text{Faux Positifs}}$. C'est la proportion d'éléments sélectionnés qui sont réellement pertinents. Autrement dit, lorsque le modèle affirme « C'est un homme », à quelle fréquence a-t-il réellement raison ?




FIGURE 4.2 – Comparaison des métriques de classification au seuil de décision $p = 0,5$.

Analyse comparative des modèles :

Le **Modèle 1** (Indice de Manning) souffre d'un biais de sélection critique. Son Rappel est très élevé (79.07 %) car son ensemble « d'éléments sélectionnés » est extrêmement vaste : le modèle repère bien les hommes, mais parce qu'il classe presque tout le monde dans cette catégorie. Conséquence directe, sa Spécificité s'effondre à 36.84 %, prouvant que le modèle sélectionne à tort une majorité de femmes (Faux Positifs). Ce volume de Faux Positifs détruit sa Précision, qui tombe à 58.62 % : près d'une prédiction « Homme » sur deux est en réalité fausse. Ces métriques de confusion, propres à notre approche par régression logistique, s'alignent avec une cohérence remarquable sur le taux d'erreur empirique de 45 % mis en évidence par l'analyse discriminante dans les récents travaux de Ballouard, Cardot et Tardivel [14]. Le fait que deux paradigmes statistiques fondamentalement différents se heurtent aux mêmes impasses prédictives lorsqu'ils sont évalués sur ce seul ratio scelle un constat sans appel : l'indice de Manning est intrinsèquement inapte à discriminer le sexe de manière isolée.

Le **Modèle 3** (Variables Brutes), en revanche, corrige ce déséquilibre géométrique et offre un compromis robuste. Le modèle fait preuve de symétrie : son Rappel (69.77 %) et sa Spécificité (71.05 %) sont équilibrés. L'ensemble des éléments sélectionnés se superpose beaucoup mieux à l'ensemble des éléments pertinents, ce qui fait bondir la Précision à 73.17 %. Ce modèle garantit que lorsqu'un individu est sélectionné comme homme, cette prédiction est significativement plus fiable que celle de l'Indice de Manning.




FIGURE 4.3 – Courbes ROC évaluant la capacité discriminante globale des trois modèles en traçant le Rappel en fonction du taux de Faux Positifs.

La Figure 4.3 confirme l'infériorité globale de l'Indice de Manning indépendamment du seuil de sélection retenu. L'aire sous la courbe (AUC) synthétise la performance globale du classement. Le Modèle Brut maximise cette aire (AUC = 0.798), surclassant strictement l'approche par ratio.

4.1.7 Frontière de Décision et Généralisation

Pour visualiser comment notre meilleur algorithme (le Modèle 3) prend ses décisions, nous avons tracé son hyperplan séparateur directement sur les données.




FIGURE 4.4 – Frontière de décision géométrique du Modèle Brut Optimal. L'hyperplan sépare l'espace en deux zones de prédiction.

En notant x_1 la taille standardisée de l'index et x_2 la largeur standardisée de la paume, l'équation de cette droite $\pi(x^T \hat{\beta}) = 0,5$ est directement issue des coefficients calculés :

$$x_2 = -\frac{\hat{\beta}_0}{\hat{\beta}_2} - \frac{\hat{\beta}_1}{\hat{\beta}_2} x_1. \quad (4.1)$$

Cette Figure 4.4 est essentielle car elle illustre parfaitement le concept de « chevauchement » décrit au Chapitre 1 (Section 1.3.2). On observe qu'aucune droite ne peut séparer parfaitement les points bleus (Hommes) des points oranges (Femmes). C'est précisément parce que les données se mélangent au centre que notre algorithme peut fonctionner correctement. Si les groupes étaient parfaitement séparés, les coefficients partiraient vers l'infini et le modèle s'effondrerait.

Enfin, pour vérifier que cette droite n'est pas un coup de chance qui aurait appris les données par cœur (surapprentissage), nous avons soumis ce modèle à une Validation Croisée à 5 plis (*K-Fold CV*). Le principe est de cacher une partie des données à l'algorithme, de l'entraîner, puis de le tester sur ces données inconnues.

L'exactitude moyenne sur les données invisibles s'établit à 71,54 %. Le fait que ce score soit légèrement supérieur à l'exactitude d'entraînement initiale (70,37 %) — un phénomène courant sur les échantillons de taille modérée — exclut tout soupçon de surapprentissage. De plus, l'AUC moyenne calculée lors de cette validation croisée s'élève à 0.834. Cela prouve que notre approche est robuste, généralisable, et valide définitivement l'intérêt de la régression logistique multivariée face aux ratios empiriques.

4.2 Stress-Test Algorithmique sur Données Massives

L'évaluation de la robustesse des algorithmes d'optimisation développés au Chapitre 2 nécessite une confrontation à des structures de données de plus grande dimension. Nous utilisons pour cela le jeu de données *Adult Census Income*, issu de la base de données *UCI Machine Learning Repository*. Ce choix se justifie par la mixité de ses variables et la présence de modalités rares, offrant un cadre d'étude idéal pour tester la stabilité de nos solveurs face à des matrices potentiellement mal conditionnées.

4.2.1 Présentation et Préparation du Jeu de Données

Le jeu de données original, extrait du recensement américain de 1994, vise à prédire si le revenu annuel d'un individu excède le seuil de 50 000 \$ ($Y = 1$) ou non ($Y = 0$). Avant l'injection dans notre moteur de calcul en C++, un protocole de préparation en trois étapes a été appliqué sous environnement R :

1. **Nettoyage et Filtrage** : Le fichier brut comporte 32 561 observations. Nous avons identifié et supprimé les lignes contenant des valeurs manquantes (notées « ? » dans les colonnes *work-class*, *occupation* et *native-country*). Cette étape de nettoyage systématique réduit l'échantillon à $n = 30\,162$ individus complets pour la phase d'entraînement.
2. **Codage Disjonctif et Indépendance Linéaire** : Les variables explicatives sont de nature hétérogène (continues comme l'âge, ou catégorielles comme le statut matrimonial). Nous avons appliqué un encodage disjonctif complet (*One-Hot Encoding*). Afin de respecter l'hypothèse de plein rang de la matrice X (Section 1.3.1), nous avons supprimé la variable `education_num`, redondante avec les modalités de la variable `education`. Par ailleurs, la création d'une colinéarité structurelle a été évitée en retranchant systématiquement une modalité de référence par catégorie.
3. **Standardisation et Dimensionnement** : Les variables quantitatives ont été centrées et réduites pour éviter que les écarts d'échelles ne dégradent numériquement la recherche de direction de descente. La matrice d'expérience résultante X , de dimension $30\,162 \times 96$, présente une structure creuse sur ses colonnes binaires, ce qui constitue le principal défi de convergence pour nos algorithmes.

4.2.2 Analyse de la Convergence et Topologie du Coût

L'exécution des méthodes numériques sur la matrice de données *Adult* ($n = 30\,162$, $p = 96$) met en évidence des comportements algorithmiques disparates, dont l'origine réside dans la géométrie complexe de la fonction de log-vraisemblance.

Conditionnement et limites du premier ordre

La topologie de la fonction de coût $J(\beta)$ présente ici un très mauvais conditionnement, caractérisé par un rapport extrême entre les valeurs propres de la matrice d'information de Fisher ($\kappa = \lambda_{max}/\lambda_{min}$). La présence de variables indicatrices déséquilibrées (associées à des modalités rares) induit des valeurs propres proches de zéro. D'un point de vue géométrique, les courbes de niveau sont fortement étirées, créant une zone de convergence très longue et peu inclinée.

Face à cette topologie, la **Descente de Gradient classique** s'est heurtée à un mur géométrique, nous poussant à mener une investigation algorithmique poussée pour tenter de forcer sa convergence :

- **Sécurisation du pas (Armijo)** : L'application d'une recherche linéaire d'Armijo a permis d'éviter la divergence algorithmique (explosion du coût) en réduisant drastiquement le pas face aux parois abruptes de la vallée. Cependant, ce sous-dimensionnement du pas a figé l'algorithme dans des micro-oscillations transversales.
- **Initialisation par la proportion empirique** : Au lieu de commencer l'algorithme avec un vecteur d'initialisation $\hat{\beta} = \mathbf{0} \in \mathbb{R}^p$, nous avons exploité une information simple : la proportion $\bar{p}$ d'individus gagnant plus de 50 000 \$ dans notre échantillon. En fixant l'ordonnée à l'origine à $\hat{\beta}_0 = \ln\left(\frac{\bar{p}}{1-\bar{p}}\right)$ (tandis que tous les autres coefficients restent nuls), le modèle prédit d'emblée la bonne proportion globale. Cette simple astuce a permis de faire chuter instantanément le coût de départ de 20 907 à 16 589, évitant ainsi à l'algorithme des itérations inutiles.
- **Pas adaptatif à mémoire** : Pour empêcher le pas d'Armijo de brider la progression au fond du canyon, nous avons implémenté une mémoire du pas de recherche ($\alpha_{t+1} = \alpha_t \times 1.5$), permettant à l'algorithme d'allonger le pas lorsque la topologie locale le permet.
- **Monitoring des dynamiques internes** : Afin de prouver formellement que l'absence de convergence relevait d'une impasse topologique et non d'une erreur d'implémentation, l'algorithme a été instrumenté pour extraire ses constantes à chaque itération (norme du gradient, pas validé, et occurrences de rejet d'Armijo). L'observation empirique d'un taux de rejet presque nul couplé à un effondrement du pas d'apprentissage ($\alpha \approx 10^{-4}$) et à une stagnation de la norme du gradient a permis de diagnostiquer et de prouver l'existence de ce couloir géométrique.

Résultat du stress-test : Malgré cette implémentation optimale, le premier ordre échoue. Poussé à un seuil extrême de **150 000 itérations**, l'algorithme a nécessité près de **45 minutes de calcul** (2719 secondes) pour atteindre un coût de 9 743,35. Incapable de franchir les derniers centièmes géométriques du canyon, il n'a jamais satisfait le critère de tolérance (10^{-4}).

L'alternative stochastique (Mini-Batch SGD)

Pour contourner la lourdeur calculatoire du gradient complet, une approche par **Mini-Batch** (lots de 128 observations) avec décroissance du taux d'apprentissage a été testée. Le bruit stochastique inhérent à l'échantillonnage a permis de traverser le plateau initial beaucoup plus rapidement (2000 époques en **34,26 secondes**). Néanmoins, ce même bruit devient un obstacle critique à l'approche du minimum : l'algorithme n'atteint jamais la véritable zone de convergence. La variance des gradients estimés le confine dans une région géométrique où le coût oscille perpétuellement autour de 9 752, le maintenant à une distance significative du minimum global.

Suprématie des méthodes du second ordre

Ces investigations empiriques prouvent que l'extraction de l'information de courbure n'est pas une simple optimisation logicielle, mais une nécessité absolue face à la séparation quasi-complète. En corrigeant la métrique de l'espace, les méthodes du second ordre pulvérisent l'obstacle géométrique :

- **Quasi-Newton (BFGS)** : Convergence atteinte en **132 itérations** et seulement **3,8 secondes** (coût minimal exact de 9 742,89). Pour un espace de dimension $p = 96$, ce résultat illustre élégamment la théorie : l'algorithme nécessite un nombre d'itérations légèrement supérieur à la dimension pour construire une approximation sécante stable de la matrice Hessienne inverse.
- **Newton-Raphson exact (IRLS)** : Convergence en **14 itérations** et **0,8 seconde**. En calculant et en inversant la Hessienne exacte $\nabla^2 J(\beta) = X^T W(\beta) X$ à chaque pas, l'algorithme bénéficie d'une vitesse de convergence quadratique, redressant intégralement l'espace déformé

dès les premières itérations.

L'optimisation de l'allocation mémoire via la bibliothèque C++ **Eigen** s'avère ici cruciale : elle permet d'exécuter ces inversions matricielles répétées sur 30 162 observations avec une vitesse garantissant la viabilité industrielle du second ordre.

Validation empirique de l'unicité et de la précision

Le succès de l'optimisation est confirmé par la comparaison des vecteurs de paramètres finaux $\hat{\beta}$. Les algorithmes BFGS et IRLS convergent vers un coût identique de 9 742,89. L'examen des dix premiers coefficients révèle une identité quasiment parfaite (ex : $\hat{\beta}_0 = -3,66359$ pour les deux méthodes), prouvant que malgré la complexité du paysage de calcul, les deux approches atteignent le minimum global unique garanti par la régularisation de Ridge.

Synthèse des performances comparées

Algorithme	Itérations	Temps de calcul (s)	Coût Final	Statut de convergence
Gradient Complet	2 000*	49,58	9 773,35	Limite atteinte
Mini-Batch SGD (128)	2 000*	34,26	9 752,18	Limite atteinte (Oscillations)
Quasi-Newton (BFGS)	132	4,59	9 742,89	Convergé (Tolérance atteinte)
Newton-Raphson (IRLS)	14	0,96	9 742,89	Convergé (Tolérance atteinte)

TABLE 4.2 – Comparaison des performances des algorithmes d'optimisation sur le jeu de données Adult ($n = 30\,162$, $p = 96$). *La limite a été fixée à 2 000 itérations pour ce test comparatif.

Les tests chronométrés (synthétisés dans le **Tableau 4.2**) illustrent la hiérarchie des méthodes :

- **Gradient Complet** : 49,58 s pour un coût de 9 773,35. L'algorithme est encore loin de l'optimum, illustrant une dérive asymptotique inefficace.
- **Mini-Batch SGD** : 34,26 s pour un coût de 9 752,18. Plus rapide que le gradient complet, il ne parvient cependant pas à atteindre la précision du second ordre.
- **BFGS** : 4,59 s pour une convergence totale. C'est le meilleur compromis entre complexité d'implémentation et performance.
- **IRLS** : 0,96 s pour une convergence totale. C'est la référence absolue de ce projet, offrant une précision exceptionnelle en un temps record grâce à l'exploitation directe de la matrice d'Information de Fisher.

4.2.3 Comparaison des Estimateurs et Paradoxe de Hauck-Donner

Nous comparons l'estimateur $\hat{\beta}$ issu de notre algorithme IRLS (intégrant une pénalité Ridge $\lambda = 10^{-5}$) avec l'estimateur par maximum de vraisemblance (MLE) de la fonction `glm` de R.

Variable	$\hat{\beta}$ (C++ Ridge)	$\hat{\beta}$ (R glm)	Différence
native_countryHoland-Netherlands	-6,683	-11,636	4,953
educationPreschool	-17,167	-20,080	2,913
native_countryOutlying-US...	-10,858	-13,420	2,562
workclassWithout-pay	-10,849	-13,288	2,439

TABLE 4.3 – Variables présentant les plus fortes divergences dues à la séparation quasi-complète.

Ces écarts sont la conséquence directe de la *séparation quasi-complète* (Section 1.3.2). Pour les variables comme `educationPreschool`, aucune observation du dataset ne présente de revenu supérieur

à 50 000 \$. En l'absence de régularisation, le solveur de R diverge en tentant d'atteindre un coefficient infini et s'arrête prématurément par épuisement de sa tolérance numérique. Notre implémentation stabilise l'estimation grâce à la contrainte Ridge.

Ce phénomène illustre le **Paradoxe de Hauck-Donner** [9] : pour ces variables, l'erreur standard asymptotique croît plus vite que le coefficient lui-même, ce qui conduit à une statistique de test $Z = \hat{\beta}/SE(\hat{\beta})$ proche de zéro et, par conséquent, à une p-valeur non significative pour des variables pourtant hautement discriminantes.

Validation de l'intégrité globale du modèle

L'analyse exhaustive des 96 coefficients montre que pour 95 % des variables explicatives, l'écart entre l'estimateur de R et notre estimateur C++ est inférieur à 10^{-6} . Le tableau ci-dessous présente les cinq variables ayant les plus faibles divergences, confirmant que la pénalité Ridge $\lambda = 10^{-5}$ n'a aucune influence sur les dimensions ne subissant pas de séparation.

Variable	$\hat{\beta}$ (C++ Ridge)	$\hat{\beta}$ (R glm)	Différence
age	0,33702858	0,33702858	$6,9 \cdot 10^{-10}$
hours_per_week	0,35413330	0,35413321	$8,9 \cdot 10^{-8}$
capital_loss	0,25999026	0,25999040	$1,3 \cdot 10^{-7}$
fnlwgt	0,07939288	0,07939275	$1,3 \cdot 10^{-7}$
sexMale	0,86482122	0,86482105	$1,6 \cdot 10^{-7}$

TABLE 4.4 – Preuve de non-pollution : égalité numérique sur les variables saines.

Critères d'Information et Parcimonie

L'évaluation de la performance du modèle repose sur un double arbitrage : la significativité statistique globale et la parcimonie de l'espace des paramètres.

Validation globale (LRT) : L'adéquation du modèle est d'abord confirmée par le test du Rapport de Vraisemblance (LRT). Avec une statistique de 14 364,94 et une p-valeur de 0 ($p < 10^{-16}$), le modèle complet est significativement supérieur au modèle nul (sans variables). Cette première étape valide la présence d'un signal prédictif réel dans les données.

Arbitrage de parcimonie (BIC) : Pour s'assurer que cette performance ne résulte pas d'un simple surapprentissage dû aux 96 paramètres introduits, nous utilisons le critère de Schwarz (BIC) [10]. Ce critère pénalise la log-vraisemblance en fonction de la taille de l'échantillon ($n = 30\,162$) et du nombre de variables ($k = 96$).

- **Modèle Nul** : $BIC = 33\,861$
- **Modèle Complet** : $BIC = 20\,476$
- **Écart** : $\Delta BIC = 13\,385$

Interprétation du gain : L'analyse de cet écart permet de quantifier précisément la balance bénéfice-risque de la complexité du modèle :

1. **Pénalité théorique** : Le terme de complexité $k \ln(n)$, qui sanctionne l'ajout des 96 paramètres, n'augmente le score BIC que d'environ 990 points.
2. **Gain net** : La réduction de la déviance obtenue par le modèle complet est plus de 13 fois supérieure à cette pénalité.

3. **Conclusion sur la parcimonie :** Un tel écart démontre que l'augmentation de la dimension de l'espace n'introduit pas de bruit inutile, mais capture une structure d'information massive qui surcompense largement le coût de complexité et le risque de surapprentissage.

En conclusion, l'information extraite par nos variables surcompense largement le coût algorithmique lié à la dimension de l'espace. Le modèle est donc non seulement performant, mais aussi mathématiquement justifié au regard du principe de parcimonie.

Le piège des grands échantillons : Significativité statistique vs Pertinence pratique

Lors de l'analyse des coefficients, le comportement de la variable `fnlwgt` (poids de redressement) met en évidence un phénomène classique mais trompeur en modélisation de données massives.

Le paradoxe observé : D'une part, le coefficient estimé est infime ($\hat{\beta}_8 = 0,0794$; $OR_8 \approx 1,08$), ce qui signifie qu'une unité supplémentaire de cette variable n'augmente la cote de succès que de 8 %, un impact quasiment négligeable dans ce contexte. D'autre part, sa p-valeur est extrêmement petite ($2 \cdot 10^{-5}$), ce qui la classe formellement comme une variable hautement significative selon le test de Wald.

L'origine statistique du paradoxe : Cette apparente contradiction s'explique par la construction même du test de Wald, dont la sensibilité est accrue par la taille massive de notre échantillon ($n = 30\,162$). Le processus se décompose en deux temps :

1. **L'écrasement de l'erreur standard :** L'erreur standard de l'estimateur $\hat{\beta}$ suit une loi de décroissance en $1/\sqrt{n}$. Avec plus de 30 000 observations, cette précision asymptotique réduit l'erreur autour du coefficient à une valeur microscopique.
2. **L'explosion de la statistique de test :** La statistique de Wald se calcule par le ratio $Z = \frac{\hat{\beta}}{SE(\hat{\beta})}$. Lorsque le dénominateur (l'erreur standard) tend vers zéro sous le poids de n , la valeur du ratio Z augmente drastiquement, indépendamment du numérateur ($\hat{\beta}$) qui est petit. Le test devient alors "hyper-sensible" au moindre écart par rapport à zéro, transformant un effet négligeable en un résultat statistiquement significatif.

Conclusion sur l'interprétation : Le test de Wald fonctionne ici parfaitement : il rejette l'hypothèse nulle avec certitude, prouvant que le coefficient n'est pas rigoureusement égal à zéro. Cependant, il démontre l'existence d'un effet, et non son importance. Ce cas d'école souligne une règle d'or en apprentissage statistique : face à de grands échantillons, la p-valeur (force de la preuve) perd de son utilité discriminante et l'analyste doit impérativement se concentrer sur la magnitude du coefficient (pertinence de l'effet).

4.2.4 Évaluation Prédictive et Stabilité du Modèle

La robustesse prédictive de notre estimateur régularisé a été évaluée par une validation croisée à cinq plis ($K = 5$). L'objectif est de s'assurer que les performances du modèle ne sont pas dépendantes d'un découpage particulièrement favorable du jeu de données.

Les résultats démontrent une forte stabilité des scores inter-plis, avec une exactitude (Accuracy) oscillant faiblement autour d'une moyenne de **84,85 %**.




FIGURE 4.5 – Évolution des scores d'exactitude et d'AUC à travers les 5 plis de la validation croisée. La ligne pointillée rouge indique la moyenne globale de chaque métrique.

Outre l'exactitude globale, la capacité du modèle à discriminer les deux classes de revenus (supérieurs ou inférieurs à 50K\$) est mesurée par l'aire sous la courbe ROC (AUC). Avec une AUC moyenne de **0,904**, le modèle présente d'excellentes capacités de séparation, confirmant que la régularisation de Ridge appliquée pour sauver l'inversion de la matrice n'a en rien dégradé le pouvoir prédictif de l'algorithme.




FIGURE 4.6 – Courbe ROC illustrant le pouvoir discriminant du modèle (AUC = 0,9022).

4.2.5 Interprétabilité et Impact Socio-Économique des Variables

Si l'algorithme C++ garantit la convergence, l'intérêt de la régression logistique réside dans l'interprétabilité directe de ses paramètres $\hat{\beta}$. Le graphique d'importance (Figure 4.7) classe les dimensions selon leur impact sur la probabilité de dépasser le seuil de hauts revenus, conditionnellement aux autres variables du modèle.




FIGURE 4.7 – Classification des variables clés selon la magnitude de leur coefficient logit.

L'analyse de ces coefficients met en lumière trois grandes dynamiques au sein du recensement américain de 1994 :

- **Le poids déterminant du niveau d'études (Favorisants et Pénalisants) :** L'éducation agit comme le levier le plus puissant du modèle, aux deux extrêmes de l'échelle. Les diplômes supérieurs sont les moteurs principaux de la probabilité de hauts revenus, avec des rapports de cotes massifs pour le doctorat (`educationDoctorate`, $OR_{18} \approx 18,73$) et les écoles professionnelles de haut niveau (`educationProf-school`, $OR_{22} \approx 17,12$). À l'inverse, l'absence de scolarité classique agit comme un frein presque absolu : la variable `educationPreschool` présente le rapport de cotes le plus faible du modèle ($OR_{21} \approx 3,5 \cdot 10^{-8}$), constituant la cause première de la séparation quasi-complète observée précédemment.
- **Le rôle de la stabilité familiale et du patrimoine :** Outre l'éducation, l'appartenance à un foyer structuré (notamment via la variable `Married-AF-spouse`, $OR_{24} \approx 15,80$) et la réalisation de plus-values financières (`capital_gain`, $OR_{53} \approx 11,25$) se révèlent être des

indicateurs décisifs pour la classification dans la classe supérieure. À l’opposé, le travail non rémunéré (`workclassWithout-pay`, $OR_7 \approx 1,9 \cdot 10^{-5}$) ou l’emploi dans les services à la personne (`Priv-house-serv`) pénalisent fortement cette cote.

- **Le bruit statistique (Variables neutres)** : Le modèle identifie également des variables dont l’influence est pratiquement nulle sur le franchissement du seuil de 50 000 \$. Outre le poids de redressement `fnlwgt` dont la nullité pratique a déjà été démontrée, certaines situations maritales comme l’absence géographique du conjoint (`Married-spouse-absent`, $OR_{26} \approx 1,01$) présentent des rapports de cotes centrés autour de l’unité. Sur le plan socio-économique, cette modalité engendre une forte hétérogénéité financière (réception de transferts de fonds vs prise en charge isolée du foyer), ce qui brouille le signal prédictif. De même, certains secteurs d’activité manuels (`Craft-repair`, `Transport-moving`) voient leur effet neutralisé : typiques de la classe moyenne, ces métiers offrent des revenus trop dispersés autour de la médiane pour isoler une tendance claire. Ainsi, conditionnellement aux autres variables (âge, diplôme, genre), ces statuts ne procurent ni avantage ni désavantage significatif permettant de statuer sur l’appartenance à la classe des très hauts revenus.

Conclusion

L'objectif de ce mémoire était d'explorer la régression logistique au-delà de son usage conventionnel de simple instrument de prédiction statistique, en disséquant l'articulation intrinsèque entre ses fondements probabilistes et ses exigences algorithmiques. À travers cette étude, nous avons démontré que l'estimation d'une probabilité binaire, en apparence élémentaire, soulève en réalité des défis topologiques et numériques profonds.

Sur le plan théorique, l'analyse de la matrice Hessienne et des conditions d'existence de l'Estimateur du Maximum de Vraisemblance a souligné la vulnérabilité du modèle face à la séparation des données. L'introduction de la régularisation de Ridge s'est avérée être non seulement un outil de réduction de la variance, mais une nécessité topologique pour garantir la coercivité de la fonction de coût et la stabilité de l'inversion matricielle.

Sur le plan algorithmique, le développement et l'instrumentation de notre propre moteur de calcul en C++ ont permis d'éprouver les limites des solveurs classiques. Le stress-test mené sur les données massives du recensement américain a mis en évidence la suprématie des méthodes du second ordre. Face à un problème mal conditionné, la descente de gradient, même optimisée et adaptative, échoue là où l'algorithme de Newton-Raphson (IRLS) et l'approximation de Quasi-Newton (BFGS) triomphent, redressant l'espace de recherche en exploitant la courbure locale de la fonction.

Enfin, sur le plan inférentiel, l'application sur données réelles a rappelé une règle d'or de l'analyse de données : la significativité statistique ne doit jamais éclipser la pertinence pratique. La mise en évidence du paradoxe de Hauck-Donner et l'écrasement de l'erreur standard sous le poids des grands échantillons démontrent que le statisticien ne peut se soustraire à une lecture critique des intervalles de confiance et de la magnitude des effets (Odds Ratios).

En définitive, ce travail valide la pertinence d'une approche hybride, propre à l'ingénierie mathématique. Si l'algorithme de Newton-Raphson demeure la clé de voûte de l'inférence pour des espaces de dimension modérée ($n > p$), l'essor des très grandes dimensions pose une limite structurelle. Lorsque le nombre de variables dépasse le nombre d'observations ($p \gg n$), la matrice d'information de Fisher devient singulière, rendant l'inférence classique caduque. Face à cette perte du plein rang, l'intégration de pénalités de norme L_1 (Lasso) constitue un premier prolongement naturel. Par ailleurs, une extension majeure de ce travail résiderait dans le passage à la **régression logistique multivariée**. Contrairement au modèle présenté ici, cette approche permet de prédire simultanément plusieurs variables binaires interdépendantes, capturant ainsi les corrélations entre les différentes dimensions du phénomène étudié. Enfin, pour s'affranchir des contraintes de linéarité du logit, la transition vers des architectures de Deep Learning offrirait une flexibilité accrue pour modéliser des interactions complexes au sein de données massives.

Annexe A

Démonstrations Mathématiques

Démonstration A.1 : Inversion de la fonction Logit (Obtention de la Sigmoid)

L'objectif est de retrouver l'expression de la probabilité paramétrée $p_i(\beta)$ (Équation 1.2) à partir de la définition du modèle logit (Équation 1.1).

Partons de l'hypothèse de linéarité du logit pour un individu i :

$$\ln \left(\frac{p_i(\beta)}{1 - p_i(\beta)} \right) = x_i^T \beta.$$

Pour isoler $p_i(\beta)$, nous appliquons la fonction exponentielle (bijection réciproque du logarithme népérien) aux deux membres de l'égalité :

$$\frac{p_i(\beta)}{1 - p_i(\beta)} = \exp(x_i^T \beta).$$

Multiplions les deux côtés par le dénominateur $(1 - p_i(\beta))$:

$$p_i(\beta) = (1 - p_i(\beta)) \exp(x_i^T \beta).$$

Développons le terme de droite :

$$p_i(\beta) = \exp(x_i^T \beta) - p_i(\beta) \exp(x_i^T \beta).$$

Regroupons les termes en $p_i(\beta)$ sur le membre de gauche :

$$p_i(\beta) + p_i(\beta) \exp(x_i^T \beta) = \exp(x_i^T \beta).$$

Factorisons par $p_i(\beta)$:

$$p_i(\beta) (1 + \exp(x_i^T \beta)) = \exp(x_i^T \beta).$$

Enfin, en divisant par le terme entre parenthèses (qui est strictement positif), nous obtenons l'expression de la fonction logistique :

$$p_i(\beta) = \frac{\exp(x_i^T \beta)}{1 + \exp(x_i^T \beta)}.$$

En multipliant numérateur et dénominateur par $\exp(-x_i^T \beta)$, on retrouve la seconde forme classique de la sigmoïde :

$$p_i(\beta) = \frac{1}{\exp(-x_i^T \beta) + 1}.$$

Ce qui conclut la démonstration.

Démonstration A.2 : Passage de la Vraisemblance à la log-vraisemblance

Nous détaillons ici les étapes algébriques permettant de passer de la fonction de vraisemblance $L(\beta)$ (Équation 1.3) à la log-vraisemblance $\ell(\beta)$.

Partons de l'expression de la vraisemblance pour n observations indépendantes :

$$L(\beta) = \prod_{i=1}^n p_i(\beta)^{y_i} (1 - p_i(\beta))^{1-y_i}.$$

Appliquons le logarithme népérien ($\ln$) aux deux membres. La fonction $\ln$ étant une bijection strictement croissante, elle préserve la position du maximum :

$$\ell(\beta) = \ln(L(\beta)) = \ln \left(\prod_{i=1}^n p_i(\beta)^{y_i} (1 - p_i(\beta))^{1-y_i} \right).$$

Utilisons la propriété du logarithme transformant un produit en somme ($\ln(\prod a_i) = \sum \ln(a_i)$) :

$$\ell(\beta) = \sum_{i=1}^n \ln (p_i(\beta)^{y_i} (1 - p_i(\beta))^{1-y_i}).$$

Utilisons maintenant la propriété du logarithme transformant un produit en somme à l'intérieur du terme général ($\ln(A \cdot B) = \ln A + \ln B$) :

$$\ell(\beta) = \sum_{i=1}^n [\ln(p_i(\beta)^{y_i}) + \ln((1 - p_i(\beta))^{1-y_i})].$$

Enfin, appliquons la propriété de la puissance ($\ln(a^b) = b \ln a$) pour descendre les exposants y_i et $(1 - y_i)$:

$$\ell(\beta) = \sum_{i=1}^n [y_i \ln(p_i(\beta)) + (1 - y_i) \ln(1 - p_i(\beta))]. \quad (\text{A.1})$$

Nous retrouvons bien l'expression de la log-vraisemblance utilisée pour l'optimisation.

Démonstration A.3 : Calcul du Gradient (Détail par la règle de la chaîne)

Nous détaillons ici le passage de l'équation de la log-vraisemblance (1.3) à l'équation du gradient (1.4) en suivant la méthode de décomposition terme à terme présentée manuscritement.

Soit $\ell(\beta) = \sum_{i=1}^n \ell_i$, où le terme général pour l'individu i est :

$$\ell_i = y_i \ln(p_i(\beta)) + (1 - y_i) \ln(1 - p_i(\beta)).$$

Nous cherchons la dérivée partielle de la log-vraisemblance par rapport à un coefficient β_j . Par application de la règle de dérivation en chaîne, cette dérivée se décompose en trois termes :

$$\frac{\partial \ell}{\partial \beta_j} = \sum_{i=1}^n \frac{\partial \ell_i}{\partial \beta_j} = \sum_{i=1}^n \underbrace{\frac{\partial \ell_i}{\partial p_i(\beta)}}_{(1)} \times \underbrace{\frac{\partial p_i(\beta)}{\partial \eta_i}}_{(2)} \times \underbrace{\frac{\partial \eta_i}{\partial \beta_j}}_{(3)}$$

avec $\eta_i = x_i^T \beta$ le prédicteur linéaire.

1) Dérivée par rapport à la probabilité $p_i(\beta)$

$$\frac{\partial \ell_i}{\partial p_i(\beta)} = \frac{y_i}{p_i(\beta)} - \frac{1 - y_i}{1 - p_i(\beta)}.$$

Mise au même dénominateur :

$$\frac{\partial \ell_i}{\partial p_i(\beta)} = \frac{y_i(1 - p_i(\beta)) - p_i(\beta)(1 - y_i)}{p_i(\beta)(1 - p_i(\beta))} = \frac{y_i - y_i p_i(\beta) - p_i(\beta) + y_i p_i(\beta)}{p_i(\beta)(1 - p_i(\beta))}.$$

Ce qui se simplifie en :

$$\frac{\partial \ell_i}{\partial p_i(\beta)} = \frac{y_i - p_i(\beta)}{p_i(\beta)(1 - p_i(\beta))}. \quad (\text{A.2})$$

2) Dérivée de $p_i(\beta)$ par rapport au prédicteur linéaire η_i Sachant que $p_i(\beta) = \frac{1}{1 + e^{-\eta_i}}$, la dérivée de la fonction logistique est donnée par la propriété classique :

$$\frac{\partial p_i(\beta)}{\partial \eta_i} = p_i(\beta)(1 - p_i(\beta)). \quad (\text{A.3})$$

3) Dérivée du prédicteur linéaire par rapport à β_j Puisque $\eta_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_j x_{ij} + \dots$, on a directement :

$$\frac{\partial \eta_i}{\partial \beta_j} = x_{ij} \quad (\text{A.4})$$

(où x_{ij} est la valeur de la j -ème variable pour l'individu i).

Assemblage En multipliant les trois termes obtenus, on observe la simplification des termes $p_i(\beta)(1 - p_i(\beta))$:

$$\frac{\partial \ell}{\partial \beta_j} = \sum_{i=1}^n \left[\frac{y_i - p_i(\beta)}{p_i(\beta)(1 - p_i(\beta))} \right] \times [p_i(\beta)(1 - p_i(\beta))] \times x_{ij},$$

$$\frac{\partial \ell}{\partial \beta_j} = \sum_{i=1}^n (y_i - p_i(\beta)) x_{ij}.$$

Forme Matricielle En empilant ces dérivées partielles pour tous les j (de 0 à p), nous retrouvons le produit matriciel final :

$$\nabla \ell(\beta) = X^T (y - p(\beta)).$$

Démonstration A.4 : Calcul de la matrice Hessienne (Par dérivation en chaîne)

Nous cherchons à calculer l'élément générique H_{jk} de la matrice Hessienne, défini comme la dérivée partielle de la j -ème composante du gradient par rapport à β_k .

Reprenons le résultat de l'Annexe A.3 (gradient) :

$$\frac{\partial \ell}{\partial \beta_j} = \sum_{i=1}^n x_{ij}(y_i - p_i(\beta)).$$

Pour obtenir $H_{jk} = \frac{\partial}{\partial \beta_k} \left(\frac{\partial \ell}{\partial \beta_j} \right)$, nous appliquons la règle de dérivation en chaîne sur le terme variable $(y_i - p_i(\beta))$. La dérivation se décompose en trois étapes :

$$H_{jk} = \sum_{i=1}^n x_{ij} \times \left[\underbrace{\frac{\partial(y_i - p_i(\beta))}{\partial p_i(\beta)}}_{(1)} \times \underbrace{\frac{\partial p_i(\beta)}{\partial \eta_i}}_{(2)} \times \underbrace{\frac{\partial \eta_i}{\partial \beta_k}}_{(3)} \right].$$

1) Dérivée du résidu par rapport à $p_i(\beta)$ Puisque y_i est une constante observée :

$$\frac{\partial(y_i - p_i(\beta))}{\partial p_i(\beta)} = -1.$$

2) Dérivée de la probabilité $p_i(\beta)$ par rapport au prédicteur linéaire η_i Comme vu précédemment (propriété de la sigmoïde) :

$$\frac{\partial p_i(\beta)}{\partial \eta_i} = p_i(\beta)(1 - p_i(\beta)).$$

3) Dérivée du prédicteur linéaire par rapport à β_k Le prédicteur étant $\eta_i = x_i^T \beta$:

$$\frac{\partial \eta_i}{\partial \beta_k} = x_{ik}.$$

Assemblage et Forme Matricielle En multipliant les trois termes :

$$\text{Terme dérivé} = (-1) \times [p_i(\beta)(1 - p_i(\beta))] \times x_{ik}.$$

On réinjecte ce résultat dans la somme globale :

$$H_{jk} = \sum_{i=1}^n x_{ij} (-p_i(\beta)(1 - p_i(\beta))x_{ik}) = - \sum_{i=1}^n x_{ij} \underbrace{p_i(\beta)(1 - p_i(\beta))}_{w_{i,i}} x_{ik}.$$

On reconnaît ici l'écriture scalaire du produit matriciel $-X^T W(\beta) X$ avec $W(\beta) = \text{diag}(p_i(\beta)(1 - p_i(\beta)))$. Ainsi :

$$H(\beta) = -X^T W(\beta) X. \quad (\text{A.5})$$

Démonstration A.5 : Existence de l'Estimateur du Maximum de Vraisemblance lors du chevauchement

Cette annexe formalise la preuve de l'existence et de l'unicité de l'Estimateur du Maximum de Vraisemblance (EMV) $\hat{\beta}$ lorsque les données vérifient l'hypothèse de chevauchement (*overlap*), telle qu'introduite à la Section 1.3.2 de ce mémoire. Cette démonstration repose sur les théorèmes d'analyse convexe et s'inscrit dans le formalisme établi par Silvapulle [3] et Albert et Anderson [4].

1. Cadre Rappelons l'expression algébrique de la log-vraisemblance établie à l'Équation (1.7) :

$$\ell(\beta) = \sum_{i=1}^n (y_i x_i^T \beta - \ln(1 + \exp(x_i^T \beta))) \quad (\text{A.6})$$

où $\beta \in \mathbb{R}^{p+1}$, $y_i \in \{0, 1\}$ et $x_i \in \mathbb{R}^{p+1}$.

Comme démontré dans la partie 1.3.1, si la matrice X est de plein rang, la matrice Hessienne de la log-vraisemblance $H(\beta) = -X^T W(\beta) X$ est définie négative. Par conséquent, $\ell(\beta)$ est une fonction **strictement concave** sur $\mathbb{R}^{p+1}$.

Pour qu'une fonction strictement concave admette un maximum global fini et unique (et donc que l'EMV existe), il est nécessaire et suffisant qu'elle ne possède aucune direction de récession. Autrement dit, il faut démontrer que la fonction tend vers $-\infty$ dans toutes les directions :

$$\lim_{\|\beta\| \rightarrow \infty} \ell(\beta) = -\infty. \quad (\text{A.7})$$

2. Formalisation géométrique du chevauchement Définissons les ensembles des réalisations x_i selon leur classe d'appartenance :

$$\begin{aligned} S_0 &= \{x_i \mid y_i = 0\}, \\ S_1 &= \{x_i \mid y_i = 1\}. \end{aligned}$$

Soit $\text{conv}(S)$ l'enveloppe convexe d'un ensemble S , définie par :

$$\text{conv}(S) = \left\{ \sum_{x_i \in S} \alpha_i x_i \mid \alpha_i \geq 0 \text{ et } \sum_{x_i \in S} \alpha_i = 1 \right\} \quad (\text{A.8})$$

et $\text{ri}(\text{conv}(S))$ son intérieur relatif. L'hypothèse de chevauchement strict (Hypothèse 3, Section 1.1) impose que les intérieurs relatifs des enveloppes convexes des deux classes s'intersectent dans $\mathbb{R}^{p+1}$:

$$\text{ri}(\text{conv}(S_0)) \cap \text{ri}(\text{conv}(S_1)) \neq \emptyset \quad (\text{A.9})$$

3. Raisonnement par l'absurde (Recherche d'une direction de récession) Supposons que l'EMV n'existe pas. Il existerait alors un vecteur directeur non nul $\delta \in \mathbb{R}^{p+1}$ tel que la log-vraisemblance ne diverge pas vers $-\infty$ le long de la direction $\beta + k\delta$ quand k tend vers $+\infty$. Analysons la limite de la somme en séparant les observations selon leur classe :

$$\ell(\beta + k\delta) = \sum_{i: x_i \in S_1} \underbrace{(x_i^T \beta + kx_i^T \delta - \ln(1 + \exp(x_i^T \beta + kx_i^T \delta)))}_{\text{Termes } y_i=1} + \sum_{i: x_i \in S_0} \underbrace{(-\ln(1 + \exp(x_i^T \beta + kx_i^T \delta)))}_{\text{Termes } y_i=0} \quad (\text{A.10})$$

Pour que cette expression ne diverge pas vers $-\infty$, il est impératif que chaque terme de la somme reste borné :

- **Pour les termes de succès** ($x_i \in S_1$) : Posons $u = x_i^T \beta + kx_i^T \delta$. Afin de lever toute forme indéterminée asymptotique, remarquons que l'expression s'écrit $u - \ln(1 + e^u) = \ln(e^u) - \ln(1 + e^u) = -\ln(1 + e^{-u})$. Si $x_i^T \delta < 0$, alors $u \xrightarrow{k \rightarrow \infty} -\infty$, et l'expression $-\ln(1 + e^{-u})$ diverge vers $-\infty$. À l'inverse, si $x_i^T \delta > 0$, l'argument $u \rightarrow +\infty$, ce qui donne une limite finie $-\ln(1 + 0) = 0$. Dans le cas où $x_i^T \delta = 0$, le terme est constant. Dans ces deux derniers cas, le terme reste borné. On obtient ainsi :

$$x_i^T \beta + kx_i^T \delta - \ln \left(1 + \exp \left(x_i^T \beta + kx_i^T \delta \right) \right) \xrightarrow{k \rightarrow +\infty} \begin{cases} -\infty & \text{si } x_i^T \delta < 0 \\ \text{borné} & \text{si } x_i^T \delta \geq 0 \end{cases}$$

L'existence d'un maximum impose donc : $\forall x_i \in S_1, x_i^T \delta \geq 0$.

- **Pour les termes d'échec** ($x_i \in S_0$) : Si $x_i^T \delta > 0$, l'argument de l'exponentielle tend vers $+\infty$, ce qui donne par équivalence asymptotique $-\ln(1 + e^u) \sim -u$. Le terme diverge alors vers $-\infty$. Dans le cas $x_i^T \delta \leq 0$, il reste borné. On obtient ainsi la limite :

$$-\ln \left(1 + \exp \left(x_i^T \beta + kx_i^T \delta \right) \right) \xrightarrow{k \rightarrow +\infty} \begin{cases} -\infty & \text{si } x_i^T \delta > 0 \\ \text{borné} & \text{si } x_i^T \delta \leq 0 \end{cases}$$

L'existence d'un maximum impose donc : $\forall x_i \in S_0, x_i^T \delta \leq 0$.

L'absence de maximum fini impliquerait donc l'existence d'un vecteur $\delta \neq 0$ satisfaisant les conditions de suivantes :

$$\forall x \in S_1, \quad \delta^T x \geq 0 \quad \text{et} \quad \forall x \in S_0, \quad \delta^T x \leq 0. \quad (\text{A.11})$$

Il est crucial de noter que l'égalité $\delta^T x_i = 0$ ne peut être satisfaite pour toutes les observations simultanément. En effet, cela équivaudrait matriciellement à $X\delta = \mathbf{0}$. La matrice de design X étant supposée de plein rang colonne, son noyau est trivial ($\ker(X) = \{\mathbf{0}\}$), ce qui imposerait $\delta = \mathbf{0}$. Ceci entre en contradiction directe avec l'hypothèse de départ d'une direction de récession non nulle.

4. Contradiction par le Théorème de séparation convexe Les conditions de séparation obtenues en (A.11) possèdent une interprétation géométrique explicite : elles stipulent qu'il existe un hyperplan séparateur (dont δ est le vecteur normal) capable de séparer les classes S_1 et S_0 .

Or, d'après le théorème de séparation des convexes en dimension finie établi par Rockafellar [5, Théorème 11.3, p. 97], deux ensembles convexes non vides peuvent être séparés par un hyperplan si et seulement si leurs intérieurs relatifs sont disjoints. Puisque nous avons posé par hypothèse la condition de chevauchement $\text{ri}(\text{conv}(S_0)) \cap \text{ri}(\text{conv}(S_1)) \neq \emptyset$, alors l'existence d'un tel hyperplan et d'un vecteur δ est impossible.

Conclusion Cette contradiction démontre qu'il n'existe aucun vecteur non nul δ le long duquel la log-vraisemblance resterait minorée asymptotiquement. Ainsi, la fonction diverge vers $-\infty$ dans toutes les directions. La fonction opposée $-\ell(\beta)$ est par conséquent **coercive**. Par ailleurs, puisque $\ell(\beta)$ est strictement concave (et continue), la fonction $-\ell(\beta)$ est **strictement convexe** et continue sur l'espace $\mathbb{R}^{p+1}$, qui constitue un **ensemble convexe, fermé et non vide**. D'après le théorème fondamental de l'optimisation convexe, une telle fonction admet un et un seul minimum global. Par équivalence, la log-vraisemblance $\ell(\beta)$ admet un et un seul maximum global. L'existence et l'unicité de l'Estimateur du Maximum de Vraisemblance $\hat{\beta}$ sont ainsi définitivement garanties sous la condition de chevauchement strict.

Démonstration A.6 : Majoration de la Hessienne et Constante de Lipschitz

Cette annexe détaille la preuve de la borne supérieure de la courbure pour la fonction de coût logistique $J(\beta)$ (utilisée en Section 2.1.1).

1. Définition de l'ordre de Loewner Soient A et B deux matrices symétriques réelles de taille $p \times p$. On dit que A est majorée par B au sens de Loewner, noté $A \preceq B$, si la matrice $B - A$ est semi-définie positive. Cela équivaut à dire que pour tout vecteur $\mathbf{v} \in \mathbb{R}^p$:

$$\mathbf{v}^T A \mathbf{v} \leq \mathbf{v}^T B \mathbf{v}.$$

2. Application à la Hessienne Logistique La Hessienne de la fonction de coût $J(\beta)$ est donnée par $\nabla^2 J(\beta) = X^T W(\beta) X$. Calculons la forme quadratique associée pour un vecteur arbitraire $\mathbf{v}$:

$$\begin{aligned} \mathbf{v}^T \nabla^2 J(\beta) \mathbf{v} &= \mathbf{v}^T (X^T W(\beta) X) \mathbf{v} \\ &= (X \mathbf{v})^T W(\beta) (X \mathbf{v}). \end{aligned}$$

Posons $\mathbf{u} = X \mathbf{v}$. La matrice $W(\beta)$ étant diagonale avec $w_{i,i}(\beta) = p_i(\beta)(1 - p_i(\beta))$, nous avons :

$$\mathbf{v}^T \nabla^2 J(\beta) \mathbf{v} = \sum_{i=1}^n w_{i,i}(\beta) u_i^2 = \sum_{i=1}^n p_i(\beta)(1 - p_i(\beta)) (\mathbf{x}_i^T \mathbf{v})^2.$$

Or, la fonction $f(p) = p(1 - p)$ est une parabole concave sur $[0, 1]$ dont le maximum est atteint en $p = 0.5$ et vaut 0.25. Par conséquent, $\forall i, \forall \beta$, on a $p_i(\beta)(1 - p_i(\beta)) \leq \frac{1}{4}$.

Nous pouvons donc majorer la somme :

$$\sum_{i=1}^n p_i(\beta)(1 - p_i(\beta)) (\mathbf{x}_i^T \mathbf{v})^2 \leq \sum_{i=1}^n \frac{1}{4} (\mathbf{x}_i^T \mathbf{v})^2.$$

Le terme de droite peut être réécrit sous forme matricielle :

$$\sum_{i=1}^n \frac{1}{4} u_i^2 = \frac{1}{4} \mathbf{u}^T \mathbf{u} = \frac{1}{4} (X \mathbf{v})^T (X \mathbf{v}) = \mathbf{v}^T \left(\frac{1}{4} X^T X \right) \mathbf{v}.$$

3. Conclusion Nous avons démontré l'inégalité matricielle suivante :

$$\nabla^2 J(\beta) \preceq \frac{1}{4} X^T X.$$

La constante de Lipschitz L correspond par définition à la courbure maximale de la fonction. Elle est donc égale à la plus grande valeur propre (rayon spectral) de cette matrice majorante. Nous obtenons ainsi l'expression explicite de L :

$$L = \frac{1}{4} \lambda_{\max}(X^T X). \quad (\text{A.12})$$

Démonstration A.7 : Dérivation détaillée de Newton-Raphson

L'algorithme de Newton-Raphson repose sur l'approximation locale de la fonction de coût $J(\beta)$ par une fonction quadratique $Q(\beta)$. Nous détaillons ici le calcul de sa dérivée pour justifier la formule de mise à jour.

1. Construction de l'approximation (Taylor) Au voisinage de l'estimation courante $\beta^{(k)}$, le développement de Taylor au second ordre s'écrit comme la somme de trois termes :

$$Q(\beta) = \underbrace{J(\beta^{(k)})}_{\text{Terme 1 (Constante)}} + \underbrace{(\beta - \beta^{(k)})^T \nabla J(\beta^{(k)})}_{\text{Terme 2 (Linéaire)}} + \underbrace{\frac{1}{2}(\beta - \beta^{(k)})^T \nabla^2 J(\beta^{(k)}) (\beta - \beta^{(k)})}_{\text{Terme 3 (Quadratique)}}. \quad (\text{A.13})$$

2. Calcul du Gradient (Terme à terme) Pour trouver le minimum, nous devons annuler le gradient de Q par rapport à β . Calculons la dérivée de chaque terme séparément :

- **Dérivée du Terme 1 (Constante)** : Le terme $J(\beta^{(k)})$ est une valeur numérique fixée à l'itération précédente. Elle ne dépend pas de la variable β .

$$\frac{\partial}{\partial \beta} [J(\beta^{(k)})] = \mathbf{0}.$$

- **Dérivée du Terme 2 (Linéaire)** : Ce terme est de la forme $\mathbf{u}^T \mathbf{v}$ avec $\mathbf{u} = (\beta - \beta^{(k)})$ et $\mathbf{v} = \nabla J(\beta^{(k)})$. Par analogie avec le cas scalaire où la dérivée de ax est a , la dérivée vectorielle par rapport à β est simplement le vecteur $\mathbf{v}$.

$$\frac{\partial}{\partial \beta} [(\beta - \beta^{(k)})^T \nabla J(\beta^{(k)})] = \nabla J(\beta^{(k)}).$$

- **Dérivée du Terme 3 (Quadratique)** : Ce terme est de la forme $\frac{1}{2} \mathbf{u}^T \nabla^2 J \mathbf{u}$. Rappelons une propriété fondamentale du calcul matriciel : si $\nabla^2 J$ est une matrice symétrique (ce qui est le cas de la Hessienne), la dérivée de la forme quadratique $\mathbf{u}^T \nabla^2 J \mathbf{u}$ par rapport à $\mathbf{u}$ est $2 \nabla^2 J \mathbf{u}$. La dérivée du terme complet est donc :

$$\frac{\partial}{\partial \beta} (\text{Terme 3}) = \frac{1}{2} \times [2 \nabla^2 J(\beta^{(k)}) (\beta - \beta^{(k)})].$$

Le facteur $\frac{1}{2}$ et le 2 se simplifient :

$$\frac{\partial}{\partial \beta} (\text{Terme 3}) = \nabla^2 J(\beta^{(k)}) (\beta - \beta^{(k)}).$$

3. Résolution de l'équation En sommant les trois dérivées et en égalant le résultat à zéro (condition de premier ordre), nous obtenons :

$$\mathbf{0} + \nabla J(\beta^{(k)}) + \nabla^2 J(\beta^{(k)}) (\beta - \beta^{(k)}) = \mathbf{0}.$$

Nous cherchons à isoler le nouveau vecteur β . Passons le gradient de l'autre côté :

$$\nabla^2 J(\beta^{(k)}) (\beta - \beta^{(k)}) = -\nabla J(\beta^{(k)}).$$

En multipliant à gauche par l'inverse de la Hessienne $[\nabla^2 J(\beta^{(k)})]^{-1}$:

$$\beta - \beta^{(k)} = -[\nabla^2 J(\beta^{(k)})]^{-1} \nabla J(\beta^{(k)}).$$

D'où la formule finale de l'algorithme :

$$\beta^{(k+1)} = \beta^{(k)} - [\nabla^2 J(\beta^{(k)})]^{-1} \nabla J(\beta^{(k)}). \quad (\text{A.14})$$

Démonstration A.8 : Équivalence Algébrique avec l'IRLS

Cette démonstration détaille le passage de la méthode de Newton aux équations des Moindres Carrés Pondérés présentées dans la section 2.2.2.

1. Factorisation de la mise à jour (Obtention de la forme matricielle) Partons de l'équation de Newton :

$$\beta^{(k+1)} = \beta^{(k)} + (X^T W^{(k)} X)^{-1} X^T (\mathbf{y} - \mathbf{p}^{(k)}).$$

Nous voulons faire apparaître la structure $(X^T W^{(k)} X)^{-1} X^T W^{(k)} \mathbf{z}^{(k)}$. Pour cela, nous injectons l'identité $I = (X^T W^{(k)} X)^{-1} (X^T W^{(k)} X)$ devant le terme $\beta^{(k)}$:

$$\beta^{(k)} = (X^T W^{(k)} X)^{-1} (X^T W^{(k)} X) \beta^{(k)}.$$

L'équation devient :

$$\beta^{(k+1)} = (X^T W^{(k)} X)^{-1} (X^T W^{(k)} X) \beta^{(k)} + (X^T W^{(k)} X)^{-1} X^T (\mathbf{y} - \mathbf{p}^{(k)}).$$

En factorisant :

$$\beta^{(k+1)} = (X^T W^{(k)} X)^{-1} \left[(X^T W^{(k)} X) \beta^{(k)} + X^T (\mathbf{y} - \mathbf{p}^{(k)}) \right].$$

Dans le crochet, nous factorisons par $X^T W^{(k)}$. Pour le second terme, nous utilisons l'astuce $I = W^{(k)} (W^{(k)})^{-1}$:

$$X^T (\mathbf{y} - \mathbf{p}^{(k)}) = X^T W^{(k)} (W^{(k)})^{-1} (\mathbf{y} - \mathbf{p}^{(k)}).$$

On obtient alors l'équation factorisée (Eq. 2.14) :

$$\beta^{(k+1)} = (X^T W^{(k)} X)^{-1} X^T W^{(k)} \left[X \beta^{(k)} + (W^{(k)})^{-1} (\mathbf{y} - \mathbf{p}^{(k)}) \right].$$

2. Identification de la variable ajustée $\mathbf{z}$ Le terme entre crochets correspond à la définition de $\mathbf{z}^{(k)}$. Vérifions sa forme scalaire pour la ligne i :

$$z_i^{(k)} = (X \beta^{(k)})_i + \left[(W^{(k)})^{-1} (\mathbf{y} - \mathbf{p}^{(k)}) \right]_i.$$

Sachant que $W^{(k)}$ est diagonale avec $w_{i,i}^{(k)} = p_i^{(k)}(1 - p_i^{(k)})$:

$$z_i^{(k)} = \eta_i^{(k)} + \frac{y_i - p_i^{(k)}}{p_i^{(k)}(1 - p_i^{(k)})}.$$

Ceci valide la formule de la variable de travail $\mathbf{z}^{(k)}$. L'algorithme s'écrit donc sous la forme compacte :

$$\beta^{(k+1)} = (X^T W^{(k)} X)^{-1} X^T W^{(k)} \mathbf{z}^{(k)}. \quad (\text{A.15})$$

3. Preuve de l'équivalence avec la minimisation (WLS) Il reste à prouver que cette solution matricielle correspond bien à la minimisation de la somme des carrés.

Soit la fonction de coût locale des moindres carrés $S(\beta) = \sum_{i=1}^n w_{i,i}^{(k)} (z_i^{(k)} - \mathbf{x}_i^T \beta)^2$. Sous forme matricielle :

$$S(\beta) = (\mathbf{z}^{(k)} - X\beta)^T W^{(k)} (\mathbf{z}^{(k)} - X\beta).$$

Pour minimiser S , nous annulons son gradient par rapport à β :

$$\nabla S(\beta) = -2X^T W^{(k)} (\mathbf{z}^{(k)} - X\beta) = \mathbf{0}$$

$$X^T W^{(k)} X\beta = X^T W^{(k)} \mathbf{z}^{(k)}.$$

La solution $\hat{\beta}$ est donc :

$$\hat{\beta} = (X^T W^{(k)} X)^{-1} X^T W^{(k)} \mathbf{z}^{(k)}.$$

Nous constatons que cette solution $\hat{\beta}$ est identique à l'expression (A.15) dérivée de Newton. Conclusion : L'algorithme de Newton-Raphson résout bien, à chaque étape, le problème de minimisation des moindres carrés pondérés.

Démonstration A.9 : Justification de la mise à jour BFGS

La puissance de l'algorithme BFGS réside dans sa capacité à construire directement une approximation de l'inverse de la Hessienne, notée $D^{(k)}$, sans jamais inverser de matrice.

Soit $\mathbf{s}^{(k)} = \beta^{(k+1)} - \beta^{(k)}$ le déplacement des paramètres et $\mathbf{q}^{(k)} = \nabla J(\beta^{(k+1)}) - \nabla J(\beta^{(k)})$ la variation du gradient de la fonction de coût. L'approximation de la Hessienne $B^{(k+1)}$ doit satisfaire l'équation sécante :

$$B^{(k+1)} \mathbf{s}^{(k)} = \mathbf{q}^{(k)}. \quad (\text{A.16})$$

La formule de mise à jour de la Hessienne (dédue de la minimisation de la norme de Frobenius sous contrainte sécante et de symétrie) s'écrit :

$$B^{(k+1)} = B^{(k)} + \frac{\mathbf{q}^{(k)} (\mathbf{q}^{(k)})^T}{(\mathbf{q}^{(k)})^T \mathbf{s}^{(k)}} - \frac{B^{(k)} \mathbf{s}^{(k)} (\mathbf{s}^{(k)})^T B^{(k)}}{(\mathbf{s}^{(k)})^T B^{(k)} \mathbf{s}^{(k)}}. \quad (\text{A.17})$$

Toutefois, l'algorithme nécessite l'inverse $D^{(k+1)} = (B^{(k+1)})^{-1}$. Au lieu d'inverser cette matrice à chaque étape (ce qui coûterait $\mathcal{O}(p^3)$ opérations), nous appliquons le lemme d'inversion matricielle de **Sherman-Morrison-Woodbury**. Ce théorème fondamental d'algèbre linéaire stipule que l'inverse d'une matrice perturbée par un terme de rang 1 (ou 2) peut être calculé directement à partir de l'inverse de la matrice originelle.

En posant $\rho^{(k)} = \frac{1}{(\mathbf{q}^{(k)})^T \mathbf{s}^{(k)}}$ et en appliquant Sherman-Morrison à l'équation de $B^{(k+1)}$, nous obtenons directement la formule de mise à jour pour $D^{(k+1)}$ implémentée dans notre programme C++ :

$$D^{(k+1)} = \left(I - \rho^{(k)} \mathbf{s}^{(k)} (\mathbf{q}^{(k)})^T \right) D^{(k)} \left(I - \rho^{(k)} \mathbf{q}^{(k)} (\mathbf{s}^{(k)})^T \right) + \rho^{(k)} \mathbf{s}^{(k)} (\mathbf{s}^{(k)})^T. \quad (\text{A.18})$$

Vérifions enfin que cette matrice inverse satisfait bien la condition sécante duale $D^{(k+1)} \mathbf{q}^{(k)} = \mathbf{s}^{(k)}$:

$$\begin{aligned} D^{(k+1)} \mathbf{q}^{(k)} &= \left(I - \rho^{(k)} \mathbf{s}^{(k)} (\mathbf{q}^{(k)})^T \right) D^{(k)} \left(I - \rho^{(k)} \mathbf{q}^{(k)} (\mathbf{s}^{(k)})^T \right) \mathbf{q}^{(k)} + \rho^{(k)} \mathbf{s}^{(k)} (\mathbf{s}^{(k)})^T \mathbf{q}^{(k)} \\ &= \left(I - \rho^{(k)} \mathbf{s}^{(k)} (\mathbf{q}^{(k)})^T \right) D^{(k)} \left(\mathbf{q}^{(k)} - \rho^{(k)} \mathbf{q}^{(k)} \left((\mathbf{s}^{(k)})^T \mathbf{q}^{(k)} \right) \right) + \mathbf{s}^{(k)} \left(\rho^{(k)} (\mathbf{s}^{(k)})^T \mathbf{q}^{(k)} \right). \end{aligned}$$

Puisque $\rho^{(k)} = \frac{1}{(\mathbf{s}^{(k)})^T \mathbf{q}^{(k)}}$, le terme $\rho^{(k)}(\mathbf{s}^{(k)})^T \mathbf{q}^{(k)} = 1$. Ainsi :

$$\begin{aligned} D^{(k+1)} \mathbf{q}^{(k)} &= \left(I - \rho^{(k)} \mathbf{s}^{(k)} (\mathbf{q}^{(k)})^T \right) D^{(k)} (\mathbf{q}^{(k)} - \mathbf{q}^{(k)}) + \mathbf{s}^{(k)} (1) \\ &= \mathbf{0} + \mathbf{s}^{(k)} = \mathbf{s}^{(k)}. \end{aligned}$$

La condition sécante est donc respectée, garantissant que $D^{(k+1)}$ intègre correctement la nouvelle courbure observée entre les itérations k et $k+1$.

Démonstration A.10 : La distribution de Bernoulli et la famille exponentielle

Soit un modèle statistique $(\mathcal{X}, \mathcal{B}, \{P_\omega; \omega \in \Omega\})$. Ce modèle appartient à la famille exponentielle si le support de la loi, $\text{supp}(P_\omega)$, est indépendant du paramètre ω , et s'il existe un entier $d \geq 1$ tel que la densité (ou la fonction de probabilité) $f(\cdot; \omega)$ s'écrit sous la forme :

$$f(x; \omega) = \exp \left(\sum_{i=1}^d C_i(\omega) T_i(x) - D(\omega) + S(x) \right) \quad \forall x \in \mathcal{X}. \quad (\text{A.19})$$

où $C_1, \dots, C_d$ et D sont des fonctions réelles définies sur l'espace des paramètres Ω , et $T_1, \dots, T_d$ et S sont des fonctions réelles définies sur l'espace des observations $\mathcal{X}$.

Dans le cadre de la régression logistique, la variable réponse Y suit une loi de Bernoulli de paramètre $p \in]0, 1[$. Considérons une réalisation scalaire $y \in \{0, 1\}$. La fonction de probabilité s'écrit :

$$f(y; p) = P(Y = y) = p^y (1 - p)^{1-y}. \quad (\text{A.20})$$

Premièrement, le support de cette distribution est $\text{supp}(P_p) = \{0, 1\}$. Ce support est un ensemble discret fixe, indépendant du paramètre p , ce qui satisfait la première condition de la définition.

Deuxièmement, en utilisant l'identité algébrique $a = \exp(\ln(a))$ pour tout réel $a > 0$, nous pouvons réécrire et développer cette fonction de probabilité :

$$\begin{aligned} f(y; p) &= \exp(\ln[p^y (1 - p)^{1-y}]) \\ &= \exp(y \ln(p) + (1 - y) \ln(1 - p)) \\ &= \exp(y \ln(p) - y \ln(1 - p) + \ln(1 - p)) \\ &= \exp(y [\ln(p) - \ln(1 - p)] + \ln(1 - p)) \\ &= \exp \left(y \ln \left(\frac{p}{1 - p} \right) - (-\ln(1 - p)) \right). \end{aligned}$$

En posant l'observation $x = y$ et le paramètre $\omega = p$, nous pouvons procéder à l'identification terme à terme avec l'Équation (A.19) pour $d = 1$:

- La fonction liée au paramètre : $C_1(p) = \ln \left(\frac{p}{1-p} \right)$
- La statistique exhaustive : $T_1(y) = y$
- La fonction de normalisation : $D(p) = -\ln(1 - p)$
- La fonction de base : $S(y) = 0$

La fonction de probabilité respectant la forme canonique exacte, la distribution de Bernoulli appartient formellement à la famille exponentielle.

Conséquence sur le lien canonique : En théorie des Modèles Linéaires Généralisés (GLM), la fonction $C_1(p)$, qui multiplie la statistique exhaustive $T_1(y)$ dans l'argument de l'exponentielle, est appelée le **paramètre naturel** de la distribution.

Dans l'architecture d'un GLM, l'objectif est de relier l'espérance de la variable (ici $\mathbb{E}[Y] = p$) au prédicteur linéaire $\eta = X\beta$ via une fonction de lien $g(p)$. Le **lien canonique** est rigoureusement défini comme la fonction g qui rend le prédicteur linéaire directement égal au paramètre naturel de la loi, c'est-à-dire $g(p) = C_1(p)$.

Par conséquent, nous obtenons :

$$g(p) = \ln \left(\frac{p}{1-p} \right). \quad (\text{A.21})$$

Ceci démontre mathématiquement que la fonction logit constitue le lien canonique de la loi de Bernoulli.

Démonstration A.11 : Normalité Asymptotique de l'EMV

Bien que le Théorème Central Limite pour le Maximum de Vraisemblance soit un résultat classique de la statistique inférentielle, il est fondamental d'en rappeler l'architecture démonstrative, car elle repose directement sur les objets matriciels définis dans ce mémoire (le vecteur Score et la matrice Hessienne).

Soit $\ell(\beta)$ la fonction de log-vraisemblance, $\mathbf{u}(\beta) = \nabla \ell(\beta)$ le vecteur Score, et $H(\beta) = \nabla^2 \ell(\beta)$ la matrice Hessienne. Par définition de l'Estimateur du Maximum de Vraisemblance $\hat{\beta}$, celui-ci annule le vecteur Score :

$$\mathbf{u}(\hat{\beta}) = 0. \quad (\text{A.22})$$

1. Développement limité de Taylor : Effectuons un développement de Taylor du premier ordre du vecteur Score autour de la vraie valeur du paramètre β :

$$\mathbf{u}(\hat{\beta}) \approx \mathbf{u}(\beta) + H(\beta)(\hat{\beta} - \beta). \quad (\text{A.23})$$

Puisque $\mathbf{u}(\hat{\beta}) = 0$, nous pouvons réarranger cette équation pour isoler l'écart entre l'estimateur et la vraie valeur :

$$-H(\beta)(\hat{\beta} - \beta) \approx \mathbf{u}(\beta) \quad \implies \quad \sqrt{n}(\hat{\beta} - \beta) \approx \left[-\frac{1}{n}H(\beta) \right]^{-1} \left[\frac{1}{\sqrt{n}}\mathbf{u}(\beta) \right]. \quad (\text{A.24})$$

2. Comportement asymptotique du vecteur Score (TCL) : Le vecteur Score $\mathbf{u}(\beta)$ est la somme des dérivées des log-vraisemblances individuelles. Sous les conditions de régularité, son espérance est nulle ($\mathbb{E}[\mathbf{u}(\beta)] = 0$) et sa variance correspond à l'Information de Fisher totale $\mathcal{I}_n(\beta)$. Par le Théorème Central Limite multivarié, la version standardisée du Score converge en loi vers une distribution Normale :

$$\frac{1}{\sqrt{n}}\mathbf{u}(\beta) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \mathcal{I}_1(\beta)). \quad (\text{A.25})$$

où $\mathcal{I}_1(\beta)$ est la matrice d'Information de Fisher asymptotique moyenne par observation.

3. Comportement asymptotique de la Hessienne (LGN) : La matrice $-\frac{1}{n}H(\beta)$ est une moyenne empirique de matrices. Par la Loi Faible des Grands Nombres, elle converge en probabilité vers son espérance mathématique, qui est par définition l'Information de Fisher :

$$-\frac{1}{n}H(\beta) \xrightarrow{\mathbb{P}} \mathcal{I}_1(\beta). \quad (\text{A.26})$$

L'application du Théorème de l'Application Continue garantit que l'inverse converge vers l'inverse :

$$\left[-\frac{1}{n}H(\beta)\right]^{-1} \xrightarrow{\mathbb{P}} \mathcal{I}_1^{-1}(\beta). \quad (\text{A.27})$$

4. Conclusion par le Théorème de Slutsky : Le Théorème de Slutsky (dans sa version multidimensionnelle) stipule que si une suite de matrices aléatoires converge en probabilité vers une matrice constante A , et qu'une suite de vecteurs aléatoires converge en loi vers un vecteur aléatoire Z , alors leur produit converge en loi vers le vecteur AZ .

En appliquant ce théorème à la décomposition isolée à l'équation (A.24), avec $A = \mathcal{I}_1^{-1}(\beta)$ et $Z \sim \mathcal{N}(0, \mathcal{I}_1(\beta))$, nous déduisons que la limite en loi de notre estimateur est celle du vecteur aléatoire $\mathcal{I}_1^{-1}(\beta)Z$.

Puisque toute transformation linéaire d'un vecteur gaussien centré reste un vecteur gaussien centré, la variance asymptotique est donnée par la forme quadratique $A\text{Var}(Z)A^T$. Sachant que la matrice d'information est symétrique, on obtient :

$$\text{Var}(\text{limite}) = \mathcal{I}_1^{-1}(\beta) \times \mathcal{I}_1(\beta) \times (\mathcal{I}_1^{-1}(\beta))^T = \mathcal{I}_1^{-1}(\beta). \quad (\text{A.28})$$

On aboutit ainsi au résultat fondamental de la normalité asymptotique :

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \mathcal{I}_1^{-1}(\beta)). \quad (\text{A.29})$$

Cette démonstration justifie l'utilisation de l'inverse de la matrice Hessienne comme matrice de variance-covariance pour le test de Wald.

Bibliographie

- [1] R. Rakotomalala, *Pratique de la régression logistique : Régression logistique binaire et polytomique*, Université Lumière Lyon 2, Version 2.0, 2011.
- [2] P. McCULLAGH et J. A. NELDER, *Generalized Linear Models*. Chapman and Hall/CRC, London, 2^{ème} édition, 1989.
- [3] M.J. Silvapulle, *On the Existence of Maximum Likelihood Estimators for the Binomial Response Models*, Journal of the Royal Statistical Society. Series B (Methodological), 43(3), 310–313, 1981.
- [4] A. ALBERT et J. A. ANDERSON, *On the existence of maximum likelihood estimates in logistic regression models*. Biometrika, 71(1), 1–10, 1984.
- [5] R. T. ROCKAFELLAR, *Convex Analysis*, Princeton University Press, 1970.
- [6] Dimitri P. BERTSEKAS, *Nonlinear Programming*. Athena Scientific, Belmont, Mass., 1^{ère} édition, 1995.
- [7] J. NOCEDAL et S. J. WRIGHT, *Numerical Optimization*. Springer Series in Operations Research, 2^{ème} édition, 2006.
- [8] T. HASTIE, R. TIBSHIRANI et J. FRIEDMAN, *The Elements of Statistical Learning : Data Mining, Inference, and Prediction*. Springer, 2^{ème} édition, 2009.
- [9] W. W. HAUCK et A. DONNER, *Wald's Test as Applied to Hypotheses in Logit Analysis*. Journal of the American Statistical Association, 72(360), 851–853, 1977.
- [10] G. E. SCHWARZ, *Estimating the dimension of a model*. Annals of Statistics, 6(2), 461–464, 1978.
- [11] D.W. Hosmer, S. Lemeshow et R.X. Sturdivant, *Applied Logistic Regression*, 3rd Edition, John Wiley & Sons, Hoboken, 2013.
- [12] H. Akaike, *A new look at the statistical model identification*, IEEE Transactions on Automatic Control, 19(6), 716–723, 1974.
- [13] S. le Cessie et J.C. van Houwelingen, *Ridge Estimators in Logistic Regression*, Journal of the Royal Statistical Society. Series C (Applied Statistics), 41(1), 191–201, 1992.
- [14] M. BALLOUARD, H. CARDOT et P. TARDIVEL, *La classification des empreintes de mains des grottes ornées*. Prépublication 2026.